



Universitat
de les Illes Balears

TREBALL DE FI DE GRAU

APRENENTATGE PER REFORÇ PROFUND PER AL JOC DEL TRUC

Josep Ferriol Font

Grau d'Enginyeria Informàtica

Escola Politècnica Superior

Any acadèmic 2025-26

APRENTATGE PER REFORÇ PROFUND PER AL JOC DEL TRUC

Josep Ferriol Font

Treball de Fi de Grau

Escola Politècnica Superior

Universitat de les Illes Balears

Any acadèmic 2025-26

Paraules clau del treball: reinforcement learning, aprenentatge per reforç, truc, jocs de cartes, DQN, PPO, N

Tutor: [NOM TUTOR]

[Agraïments]

SUMARI

Sumari	iii
Índex de figures	v
Índex de taules	vii
Llista d'acrònims	ix
Resum	xi
1 Introducció	1
1.1 La intel·ligència artificial en el joc	1
1.2 El repte de la informació parcial	1
1.3 El Truc: engany, parella i farol	2
1.4 Objectius i estructura d'aquest treball	3
2 Conclusions	5
A Hiperparàmetres dels models	7
B Resultats complets per fase	9
Bibliografia	11

ÍNDICE DE FIGURES

ÍNDEX DE TAULES

LLISTA D'ACRÒNIMS

AR	Aprenentatge per Reforç
DRL	Deep Reinforcement Learning
DQN	Deep Q-Network
PPO	Proximal Policy Optimization
NFSP	Neural Fictitious Self-Play
POMDP	Partially Observable Markov Decision Process
TFG	Treball Final de Grau

RESUM

[Resum de 250–500 paraules: problema, mètode, resultats, conclusions.]

Paraules clau: *reinforcement learning, truc, jocs de cartes, DQN, PPO, NFSP, informació parcial, curriculum learning, self-play.*

INTRODUCCIÓ

1.1 La intel·ligència artificial en el joc

Al llarg de la història, els jocs han servit com a banc de prova privilegiat per a la intel·ligència artificial (IA!). La raó és clara: un joc defineix un entorn tancat, amb regles precises i un criteri d'èxit objectiu, la qual cosa permet mesurar el progrés d'un agent de manera inequívoca. Els èxits en aquest àmbit han estat espectaculars. L'any 1997, Deep Blue derrota el campió mundial d'escacs Garry Kasparov, un fita que semblava inalcançable una dècada abans [?]. El 2016, AlphaGo supera Lee Sedol al joc del Go, un problema considerat exponencialment més complex pels seus 10^{170} estats possibles [?]. El 2019, l'agent OpenAI Five derrota equips professionals de Dota 2 en partides de cinc jugadors per banda, demostrant la viabilitat de l'Aprenentatge per Reforç (AR) en entorns multiagent de gran escala [?].

El motor comú de tots aquests avenços és el *Deep Reinforcement Learning* (o Deep Reinforcement Learning (DRL)): la combinació de l'AR clàssic amb xarxes neuronals profundes. L'AR permet a un agent aprendre comportaments òptims interactuant amb un entorn i rebent recompenses; les xarxes profundes li permeten representar espais d'estats molt complexos sense necessitat de definir les característiques rellevants manualment. Junts, han fet possible que màquines sense cap coneixement inicial assoleixin nivells sobrehumans en dominis on els humans tarden anys a dominar.

1.2 El repte de la informació parcial

Els èxits anteriors, però, es produeixen principalment en jocs d'*informació completa*: tots els jugadors veuen l'estat complet del joc en tot moment. Els escacs, el Go i els jocs de taulell en general pertanyen a aquesta categoria. En canvi, molts dels jocs que els humans troben més fascinants —i estratègicament rics— amaguen informació: les cartes dels adversaris, les intencions futures, els recursos ocults.

Formalment, un joc d'informació parcial es modela com un Partially Observable

Markov Decision Process (POMDP): l'agent rep observacions parcials de l'estat real del món i ha d'actuar sense visibilitat completa. Això introdueix un repte qualitatiu diferent, ja que l'estratègia òptima ja no consisteix a calcular la millor jugada donada la posició, sinó a raonar sobre la *distribució de probabilitat* dels estats ocults, i a vegades a explotar deliberadament la incertesa de l'adversari.

Els jocs de pòquer han estat el principal camp d'experimentació en informació parcial. El 2017, Libratus guanya jugadors professionals de Texas Hold'em de dos jugadors (*heads-up*) [?]. El 2019, Pluribus estén aquest resultat al pòquer de sis jugadors, un entorn multiagent molt més complex on les tècniques clàssiques de teoria de jocs no escalen directament [?]. Ambdós agents aproximen un *equilibri de Nash*: una estratègia tal que cap jugador pot millorar el seu resultat canviant unilateralment de política.

Malgrat aquests progressos, el camp és lluny d'estar tancat. Cada joc d'informació parcial té la seva pròpia estructura d'observació, el seu espai d'accions i les seves dinàmiques estratègiques. Un agent entrenat al pòquer no es pot transferir directament a un altre joc de cartes: cal dissenyar l'entorn, definir l'espai d'estats i triar els algorismes adequats a cada cas.

1.3 El Truc: engany, parella i farol

El Truc és un joc de cartes tradicional d'arrel catalana i valenciana, estès a Llatinoamèrica i amb una comunitat activa a les Illes Balears i al País Valencià [?]. Es juga per parelles (dos contra dos), amb l'objectiu de ser el primer equip a arribar a 24 punts —un *cantó*— en partides de millor de tres o cinc cantons.

S'usa una baralla espanyola de 40 cartes de les quals s'eliminen els 2s, deixant 36 cartes amb quatre colls (Ors, Copes, Espases i Bastos). La jerarquia de les cartes és no intuïtiva: la carta més alta no és l'as genèric, sinó l'As de Bastos (anomenat *L'Amo*), seguit del 10 d'Ors (*Sa Madona*), l'As d'Espases i l'As de Bastos, les set d'Espases i d'Ors, els tresos, la resta d'assos, les figures i finalment els valors baixos.

Cada mà es divideix en dues batalles independents:

- **L'Envit.** Abans de jugar cap carta, un jugador pot apostar sobre la força de la seva mà, calculada com la suma dels valors de dues cartes del mateix coll més 20 punts (les figures valen 0 en aquest còmput). L'escala d'apostes progressa des de *Envit* (2 punts en joc) fins a *La Falta* (tots els punts que li falten a l'equip guanyador per completar la cama). Si l'adversari no vol l'aposta, cedeix 1 punt a l'apostador.
- **El Truc.** En qualsevol moment, un jugador pot cantar *Truc*, posant 3 punts en joc. L'aposta pot escalar fins a *Retruc* (6 pts), *Quatre Val* (9 pts) i *Joc Fora* (guanya tota la cama). L'objectiu és guanyar dues de les tres rondes (*bassetges*) jugant la carta amb rang més alt en cada ronda.

La dimensió que fa del Truc un cas d'estudi especialment interessant no és, però, el seu sistema de puntuació: és el **farol**. A diferència del pòquer, on el farol és una acció aïllada, al Truc forma part de l'essència del joc. Un jugador amb una mà mediocre pot cantar Truc amb convicció esperant que l'adversari es retiri, cedint un punt sense veure les cartes. I alhora, les parelles poden comunicar informació sobre les seves mans mitjançant un sistema de *senyes* (gestos facials codificats), sempre vigilant que els rivals

no els deixin descoberts. Com resumeix la saviesa popular del joc: “*El Truc no és només matemàtiques i memòria. És un joc de cares, de silencis i de mentides.*”

Des del punt de vista formal, el Truc és un POMDP cooperatiu-competitiu: l'agent ha de gestionar informació oculta (les cartes dels adversaris i de la parella), coordinar-se amb un aliat sense comunicació verbal explícita, i decidir en cada moment si enganyar o dir la veritat sobre la força de la seva mà. Aquesta combinació de factors el converteix en un repte d'AR substancialment diferent dels jocs estudiats fins ara en la literatura.

1.4 Objectius i estructura d'aquest treball

L'objectiu d'aquest Treball Final de Grau (TFG) és desenvolupar i avaluar agents d'Aprenentatge per Reforç (AR) capaços de jugar al Truc de manera competitiva, partint de zero i sense cap coneixement previ del joc. Concretament, el treball s'articula al voltant de tres objectius principals:

1. **Modelització de l'entorn.** Dissenyar un simulador del Truc que implementi totes les regles del joc (envit, truc, apostes, puntuació i senyes), i exposar-lo com un entorn estàndard compatible amb les biblioteques d'AR existents (RLCard [?] i Stable-Baselines3 [?]).
2. **Comparació d'algorismes i tècniques d'entrenament.** Avaluar quatre algorismes —Deep Q-Network (DQN) i Neural Fictitious Self-Play (NFSP) via RLCard, i DQN i Proximal Policy Optimization (PPO) via SB3— en condicions homogènies, i estudiar l'efecte del *curriculum learning* (entrenar primer en mans individuals i després en partides senceres), de l'ús d'extractors de característiques convolucionals, de la memòria recurrent (GRU) i del *self-play* sobre la convergència i el rendiment dels agents.
3. **Avaluació.** Mesurar el rendiment de cada agent contra un agent de regles heurístiques i analitzar si els agents aprenen comportaments estratègics (gestió de l'envit, ús del farol al truc) o es limiten a polítiques reactives.

Com a objectiu addicional, s'explora la variant per parelles del Truc, que afegeix la dimensió cooperativa i la necessitat de coordinar-se amb un agent aliat.

El treball s'organitza de la manera següent. El capítol ?? presenta el marc teòric: els fonaments de l'AR, els algorismes emprats i l'estat de l'art en jocs d'informació parcial. El capítol ?? descriu la lògica del joc i l'arquitectura del simulador. El capítol ?? detalla el disseny dels entorns d'AR. El capítol ?? explica la metodologia d'entrenament per fases. El capítol ?? presenta i discuteix els resultats experimentals. Finalment, el capítol ?? recull les conclusions i les línies de treball futur.



CONCLUSIONS

[Conclusions del treball: resum del context i del problema, principals conclusions, implicacions teòriques i pràctiques, limitacions i treball futur.]



HIPERPARÀMETRES DELS MODELS

[Taules amb els hiperparàmetres complets de cada algorisme (DQN-RLCard, NFSP-RLCard, DQN-SB3, PPO-SB3) per a cada fase experimental.]

APÈNDIX

RESULTATS COMPLETS PER FASE

[Taules amb tots els valors numèrics dels experiments: mètriques finals, temps d'entrenament, etc.]

BIBLIOGRAFIA