



Universitat
de les Illes Balears

TREBALL DE FI DE GRAU

APRENENTATGE PER REFORÇ PROFUND PER AL JOC DEL TRUC

Josep Ferriol Font

Grau d'Enginyeria Informàtica

Escola Politècnica Superior

Any acadèmic 2025-26

APRENTATGE PER REFORÇ PROFUND PER AL JOC DEL TRUC

Josep Ferriol Font

Treball de Fi de Grau

Escola Politècnica Superior

Universitat de les Illes Balears

Any acadèmic 2025-26

Paraules clau del treball: aprenentatge per reforç, truc, jocs de cartes, informació parcial, curriculum learning, self-play

Tutor: Dr. Francesc Xavier Gayà Morey

Cotutor: Dr. Gabriel Moyà Alcover

Segons estudis demogràfics, una gran part de la població mundial neix en contextos on l'accés a l'educació i la sanitat no estan garantits. Tenir la sort de néixer a Europa, en un estat de dret que reconeix la salut i l'educació com a pilars fonamentals de la societat, és un privilegi que no hauria de donar-se per descomptat. Per això, vull agrair haver tingut l'oportunitat de cursar una educació pública i de qualitat a la meua terra,
Mallorca.

A més, un agraïment especial dirigit a la meua família, els altres grans patrocinadors d'aquesta carrera. El seu suport incondicional ha estat el fonament sobre el qual s'ha construït tot el que he aconseguit.

SUMARI

Sumari	iii
Índex de figures	v
Índex de taules	vii
Llista d'acrònims	ix
Resum	xi
1 Introducció	1
1.1 La intel·ligència artificial en el joc	2
1.2 El repte de la informació parcial	2
1.3 El Truc: engany, parella i farol	3
1.4 Objectius i estructura d'aquest treball	3
2 Fonaments Teòrics	5
2.1 Aprenentatge per Reforç	5
2.2 Estat de l'art en jocs d'informació parcial	6
2.3 Deep Q-Network	7
2.4 Proximal Policy Optimization	8
2.5 Curriculum Learning	8
2.6 Deep Recurrent Q-Learning	9
2.7 Self-play i equilibri de Nash	10
2.8 Neural Fictitious Self-Play	10
3 Conclusions	13
A Hiperparàmetres dels models	15
B Resultats complets per fase	17
Bibliografia	19

ÍNDICE DE FIGURES

ÍNDEX DE TAULES

LLISTA D'ACRÒNIMS

IA	Intel·ligència Artificial
AR	Aprenentatge per Reforç
DRL	Deep Reinforcement Learning
DQN	Deep Q-Network
PPO	Proximal Policy Optimization
NFSP	Neural Fictitious Self-Play
MDP	Markov Decision Process
POMDP	Partially Observable Markov Decision Process
MVC	Model-Vista-Controlador
SB3	Stable-Baselines3
GRU	Gated Recurrent Unit
TFG	Treball Final de Grau

RESUM

[Resum de 250–500 paraules: problema, mètode, resultats, conclusions.]

Paraules clau: *reinforcement learning, truc, jocs de cartes, DQN, PPO, NFSP, informació parcial, curriculum learning, self-play.*

INTRODUCCIÓ

El joc és una de les activitats més antigues de la humanitat. Abans de ser un objecte de diferents estudis, era simplement una pràctica social: un espai on les persones s'enfronten, es coordinen, negocien i, sovint, s'ensenyen mútuament. Els antropòlegs el descriuen com un mecanisme de transmissió cultural i d'entrenament de la intel·ligència, present en totes les societats conegudes [1]. Jugar no és només passar l'estona: és practicar la presa de decisions sota incertesa, gestionar el risc i llegir les intencions dels altres.

Els jocs tradicionals hi afegeixen una capa de patrimoni i cultura. Aquests no són simples entreteniments: són codis culturals transmesos de generació en generació, amb vocabulari propi, rituals i regles que reflecteixen el pensament social de cada territori. El problema és que necessiten jugadors que coincideixin al mateix lloc i al mateix moment. La dispersió geogràfica, l'envelliment dels cercles de jugadors i el canvi d'hàbits d'oci fan que sigui cada cop més difícil. Sense adversaris ni parella, el joc s'extingeix per inanició, no per desinterès.

No record exactament quan vaig aprendre a jugar a cartes. Als tretze o catorze anys ja hi jugaven tots els meus amics del poble. El que sé és que he tengut la sort de poder comptar amb els padrins, ties i altre gent, que m'han pogut ensenyar els distints jocs tradicionals, entre ells jocs de cartes. Al meu poble, jocs com el Terceti (que avui quasi ja no es juga a cap altre lloc) o el Truc formen part de la vida quotidiana, transmesos de generació en generació sense que ningú ho pensés gaire.

Però amb els anys m'he anat adonant que cada cop és més difícil trobar gent per seure a una taula. El cercle de jugadors envelleix, i quan no hi ha prou persones disponibles el Truc simplement no es pot jugar. Aquesta inquietud és el que m'ha duit a fer aquest Treball Final de Grau (TFG): crear una versió del Truc que es pugui jugar contra un agent d'aprenentatge per reforç, de manera que el joc pugui continuar viu encara que no hi hagi quatre humans disponibles.

1.1 La intel·ligència artificial en el joc

Darrerament, la relació entre jocs i Intel·ligència Artificial (IA) ha anat més lluny de la preservació cultural. Des de fa dècades, els jocs han servit també com a banc de prova per als investigadors, ja que, en ser entorns tancats amb regles precises i un criteri d'èxit mesurable, permeten avaluar algorismes de manera objectiva i reproducible. L'any 1997, Deep Blue va derrotar el campió mundial d'escacs Garry Kasparov, una fita que semblava inalcançable una dècada abans [2]. El 2016, AlphaGo va superar Lee Sedol al joc del Go, un problema considerat exponencialment més complex pels seus 10^{170} estats possibles [3]. El 2019, l'agent OpenAI Five va derrotar equips professionals de Dota 2 en partides de cinc jugadors per banda [4].

El denominador comú d'aquests avenços és el Deep Reinforcement Learning (DRL): la combinació de l'Aprenentatge per Reforç (AR) clàssic amb xarxes neuronals profundes. L'AR permet a un agent aprendre interactuant amb un entorn i rebent recompenses; les xarxes profundes li permeten representar espais d'estats molt complexos sense necessitat de definir manualment les característiques rellevants. La combinació dels dos ha permès que agents sense cap coneixement inicial arribin a nivells humans en diferents dominis (escacs, Go, Dota 2, etc.). Aquest treball segueix el mateix enfocament: xarxes neuronals profundes combinades amb AR per aprendre a jugar al Truc partint de zero.

1.2 El repte de la informació parcial

Tots aquests èxits, però, es produeixen en jocs d'*informació completa*: tots els jugadors veuen l'estat sencer del joc en tot moment. Els escacs, el Go i els jocs de taulell en general pertanyen a aquesta categoria. En canvi, molts dels jocs que els humans troben més fascinants, i estratègicament rics, amaguen informació: les cartes dels adversaris, les intencions futures, els recursos ocults.

Formalment, un joc d'informació parcial es modela com un Partially Observable Markov Decision Process (POMDP): l'agent rep observacions parcials de l'estat real del món i ha d'actuar sense visibilitat completa. L'estratègia òptima ja no consisteix a calcular la millor jugada donada la posició, sinó a raonar sobre els estats ocults i el possible comportament d'un adversari.

Els jocs de pòquer han estat el principal camp d'experimentació en informació parcial. El 2017, Libratus va guanyar jugadors professionals de Texas Hold'em de dos jugadors (*heads-up*) [5]. El 2019, Pluribus va estendre aquest resultat al pòquer de sis jugadors, un entorn multiagent molt més complex on les tècniques clàssiques de teoria de jocs no escalen directament [6]. Ambdós agents aproximen un *equilibri de Nash*: una estratègia tal que cap jugador pot millorar el seu resultat canviant unilateralment de política.

Malgrat aquests progressos, el camp és lluny d'estar tancat. Cada joc d'informació parcial té la seva pròpia estructura d'observació, el seu espai d'accions i les seves dinàmiques estratègiques. Un agent entrenat al pòquer no es pot transferir directament a un altre joc de cartes: cal dissenyar l'entorn, definir l'espai d'estats i triar els algorismes adequats a cada cas.

1.3 El Truc: engany, parella i farol

El Truc és un joc de cartes tradicional d'arrel catalana i valenciana, arrelat a les Illes Balears i al País Valencià [7]. Es juga per parelles (dos contra dos) amb una baralla espanyola de 36 cartes, i guanya el primer equip que arriba als 24 punts d'una *cama*. Cada mà es disputa en dues apostes independents: l'**Envit** (sobre la força de la mà en punts) i el **Truc** (sobre qui guanya les rondes de carta alta). Les regles completes, la jerarquia de cartes i el model formal es detallen al capítol ??.

La mecànica no és el que fa del Truc un repte per a la IA. És el **farol**: qui té cartes dolentes pot cantar Truc amb convicció i guanyar el punt sense ensenyar-les. A més, les parelles es coordinen mitjançant *senyes*, un sistema de gestos facials codificats que els adversaris poden intentar llegir i explotar. Com es diu al joc: “*El Truc no és només matemàtiques i memòria. És un joc de cares, de silencis i de mentides.*”

Tot plegat, el Truc és un POMDP cooperatiu-competitiu: l'agent ha de gestionar informació oculta, coordinar-se sense comunicació verbal explícita i decidir a cada torn si enganyar o ser sincer sobre la força de la seva mà. Aquesta combinació de factors el fa substancialment diferent dels jocs estudiats fins ara en la literatura.

1.4 Objectius i estructura d'aquest treball

Per complir amb l'objectiu d'aquest TFG (*desenvolupar i avaluar agents d'AR capaços de jugar al Truc de manera competitiva, partint de zero i sense cap coneixement previ del joc*) ens cal primer implementar una versió digital completa i jugable del Truc (incloent les modalitats de 2 vs 2 amb senyes). L'entrenament dels agents es circumscriu a la variant d'1 vs 1 sense senyes; l'extensió a agents cooperatius per parelles s'identifica com a línia de recerca futura. Concretament, el treball s'articula al voltant de tres objectius principals:

1. **Modelització, implementació i aplicació jugable.** Implementar el motor complet del joc (envit, truc, apostes i senyes) seguint una arquitectura Model-Vista-Controlador (MVC) que desacobla nítidament la lògica del joc, el control i la interfície. L'aplicació compta amb dues interfícies: consola (text) i escriptori (gràfica amb imatges de naips i interacció per ratolí). La interfície d'escriptori permet partides 1 vs 1 (humà contra humà o humà contra agent) i 2 vs 2 humà contra humà amb suport de senyes. El motor s'exposa alhora com a entorn estàndard compatible amb les biblioteques d'AR (RLCard [8] i Stable-Baselines3 [9]).
2. **Comparació d'algorismes i tècniques d'entrenament.** Avaluar quatre algorismes (Deep Q-Network (DQN) i Neural Fictitious Self-Play (NFSP) via RLCard, i DQN i Proximal Policy Optimization (PPO) via SB3) en condicions homogènies, i estudiar l'efecte del *curriculum learning* (entrenar primer en mans individuals i després en partides senceres), de l'ús d'extractors de característiques convolucionals, de la memòria recurrent (GRU) i del *self-play* sobre la convergència i el rendiment dels agents.
3. **Avaluació.** Mesurar el rendiment de cada agent contra un agent de regles heurístiques i analitzar si els agents aprenen comportaments estratègics (gestió de l'envit, ús del farol al truc) o es limiten a polítiques reactives.

1. INTRODUCCIÓ

El treball s'organitza de la manera següent. El capítol 2 presenta el marc teòric: els fonaments de l'AR, els algorismes emprats i l'estat de l'art en jocs d'informació parcial. El capítol ?? descriu la lògica del joc i l'arquitectura del simulador. El capítol ?? detalla el disseny dels entorns d'AR. El capítol ?? explica la metodologia d'aprenentatge per reforç i les fases d'entrenament. El capítol ?? presenta i discuteix els resultats experimentals. Finalment, el capítol ?? recull les conclusions i les línies de treball futur.

FONAMENTS TEÒRICS

Aquest capítol presenta els fonaments teòrics que sustenten el treball: els conceptes bàsics de l'AR, els algorismes emprats i l'estat de l'art en jocs d'informació parcial. Cada secció s'orienta específicament als components que apareixeran a la metodologia d'entrenament.

2.1 Aprenentatge per Reforç

L'AR és el paradigma d'aprenentatge automàtic en què un agent aprèn a actuar en un entorn mitjançant l'assaig i l'error, guiat per senyals de recompensa [10]. A diferència de l'aprenentatge supervisat, no existeix un professor que indiqui l'acció correcta a cada pas: l'agent ha de descobrir per si mateix quines accions condueixen a recompenses elevades.

Procés de Decisió de Markov

L'entorn es formalitza com un Markov Decision Process (MDP), definit per la tupla (S, A, P, R, γ) :

- S — conjunt d'estats de l'entorn,
- A — conjunt d'accions disponibles per a l'agent,
- $P(s' | s, a)$ — probabilitat de transitar a l'estat s' en prendre l'acció a des de l'estat s ,
- $R(s, a)$ — recompensa immediata esperada,
- $\gamma \in [0, 1)$ — factor de descompte que pondera la importància de les recompenses futures.

A cada pas de temps t , l'agent observa l'estat s_t , tria una acció a_t seguint una política $\pi(a | s)$, rep la recompensa r_t i transita a s_{t+1} .

L'objectiu de l'agent és trobar la política π^* que maximitzi el retorn acumulat descomptat $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$.

Funcions de valor

La funció de valor d'estat $V^\pi(s)$ mesura el retorn esperat des de l'estat s seguint la política π , i la funció de valor d'acció $Q^\pi(s, a)$ en fa el mateix però condicionant en l'acció inicial a :

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s \right], \quad Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s, a_t = a \right].$$

L'equació de Bellman expressa Q^* de forma recursiva:

$$Q^*(s, a) = \mathbb{E} \left[r + \gamma \max_{a'} Q^*(s', a') \right].$$

Aquesta relació de recurrència és la base de tots els algorismes de la família Q-learning.

POMDP: observació parcial

En molts entorns reals, l'agent no té accés a l'estat complet del sistema. Un Partially Observable Markov Decision Process (POMDP) estén el model MDP amb una funció d'observació $O(o | s, a)$: en lloc de s_t , l'agent rep una observació parcial o_t que conté menys informació que l'estat real.

L'entorn del Truc és un POMDP: l'agent rep una observació de 239 dimensions que inclou la seva mà i l'historial visible, però no les cartes dels adversaris. Això implica que la política òptima ha de raonar sobre la *distribució de probabilitat* dels estats ocults.

2.2 Estat de l'art en jocs d'informació parcial

El pòquer ha estat el banc de prova principal per a la IA en jocs d'informació parcial, i els sistemes basats en Minimització del Penediment Contra-factual (*Counterfactual Regret Minimization*, CFR) han assolit resultats sobrehumans.

Libratus [5] (Brown & Sandholm, 2017) guanya jugadors professionals de Texas Hold'em de dos jugadors. CFR minimitza iterativament el penediment contra-factual —la millora hipotètica si s'hagués pres una acció diferent— i convergeix a l'equilibri de Nash. Libratus resol sub-jocs en temps real per refinar la seva estratègia durant la partida.

Pluribus [6] (Brown & Sandholm, 2019) estén aquest resultat al pòquer de sis jugadors combinant Monte Carlo CFR, una estratègia de base (*blueprint*) obtinguda per self-play i la resolució de sub-jocs en temps real. És la primera IA a superar humans en un entorn multi-jugador d'informació parcial.

Limitacions dels enfocaments CFR

Malgrat els seus èxits, els sistemes basats en CFR presenten limitacions importants que motiven l'enfocament d'aquest treball:

- **Cost exponencial:** CFR necessita aproximar o enumerar l'arbre de joc complet. El cost creix exponencialment amb la profunditat i el nombre de jugadors, fent-lo inviable sense un disseny meticulós d'abstraccions específiques per a cada joc.
- **Especificitat del pòquer:** l'estructura de Texas Hold'em (cegues fixes, rondes predefinides, jugadors eliminables) facilita la partició en sub-jocs resolubles. Jocs amb apostes menys estructurades —com el Truc, on l'escala d'apostes i les senyes introdueixen dependències complexes— no es beneficien directament d'aquestes tècniques.
- **Absència de representació apresada:** CFR opera sobre historials d'accions abstractes sense xarxes neuronals compartides. Transferir l'enfocament a un nou joc requereix redissenyar l'abstracció des de zero.
- **Escalabilitat multi-jugador limitada:** la convergència a Nash que Pluribus aconsegueix amb 6 jugadors és teòricament sòlida però computacionalment intensiva i difícilment aplicable a 4+ jugadors sense recursos de supercomputació.

L'enfocament d'aquest treball, basat en DRL (DQN, PPO, NFSP), no requereix model·lar l'arbre de joc explícitament i generalitza a nous jocs sense redissenyar l'abstracció, pagant el cost d'una convergència a Nash menys garantida teòricament però més escalable en la pràctica.

2.3 Deep Q-Network

Deep Q-Network (DQN) [11] fou el primer algoritme de DRL a demostrar aprenentatge de nivell humà en entorns d'alta dimensionalitat (jocs Atari), combinant Q-learning amb xarxes neuronals profundes.

En lloc d'una taula $Q(s, a)$, DQN aproxima la funció de valor d'acció amb una xarxa neuronal $Q(s, a; \theta)$ parametritzada per θ . Aprèn minimitzant la pèrdua:

$$\mathcal{L}(\theta) = \mathbb{E}_{(s, a, r, s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right].$$

Dues innovacions clau estableixen l'entrenament:

- **Experience Replay:** les transicions (s, a, r, s') s'emmagatzemen en un buffer $\mathcal{D}$ i es mostregen aleatòriament. Això trenca la correlació temporal entre mostres consecutives, requisit per a la convergència de la xarxa.
- **Xarxa objectiu θ^- :** una còpia de θ que s'actualitza periòdicament (cada N passes) i s'usa per calcular els objectius de Bellman. Evita l'oscil·lació causada per actualitzar simultàniament la xarxa d'estimació i l'objectiu.

Per al joc del Truc, on no totes les accions són legals en cada estat, s'aplica *action masking*: les accions il·legals reben un valor de $-\infty$ abans del argmax, de manera que l'agent mai no selecciona una acció prohibida. A la Fase 1 es comparen dues implementacions de DQN: la nativa de RLCARD i la de Stable-Baselines3 (SB3).

2.4 Proximal Policy Optimization

Proximal Policy Optimization (PPO) [12] és un algoritme Actor-Critic on-policy que s'ha convertit en l'estàndard pràctic de l'AR gràcies a la seva estabilitat i eficiència computacional.

Actor-Critic

PPO manté dues xarxes: l'*actor* $\pi(a | s; \theta)$ que aprèn la política, i el *crític* $V(s; \phi)$ que estima la funció de valor. L'actor s'entrena per maximitzar el retorn esperat; el crític proporciona una línia base que redueix la variança del gradient.

L'avantatge estimat $\hat{A}_t$ mesura si l'acció presa va ser millor o pitjor del previst pel crític, i s'estima mitjançant el mètode GAE (*Generalized Advantage Estimation*).

Objectiu amb retall

La innovació central de PPO és l'objectiu amb retall (*clipped surrogate objective*), que limita l'actualització de la política per evitar passos massa grans:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_t \right) \right],$$

on $r_t(\theta) = \pi(a_t | s_t; \theta) / \pi(a_t | s_t; \theta_{\text{old}})$ és el ràtio entre la política nova i l'antiga, i $\varepsilon = 0,2$.

La pèrdua total afegeix un terme de valor $\mathcal{L}^V$ i un bonus d'entropia $\mathcal{H}[\pi]$ per mantenir l'exploració:

$$\mathcal{L} = \mathcal{L}^{\text{CLIP}} - c_1 \mathcal{L}^V + c_2 \mathcal{H}[\pi].$$

Paral·lelisme

PPO és on-policy i aprofita el paral·lelisme de manera natural: en aquest treball s'han usat 48 entorns simultanis via `SubprocVecEnv`, assolint un rendiment de ≈ 9.780 passos per segon, trenta vegades superior a NFSP-RLCARD. Aquesta capacitat de paral·lelisme és decisiva per a l'eficiència del curriculum learning de la Fase 2.

2.5 Curriculum Learning

El *curriculum learning* [13] és una estratègia d'entrenament que presenta els exemples o les tasques en ordre creixent de dificultat, imitant la manera com els humans aprenen.

En el context de l'AR, el problema que motiva l'ús del curriculum és el de la **recompensa escassa**: en una partida sencera de Truc, l'episodi pot durar fins a ~ 150 passos i el senyal de recompensa rellevant arriba tard i de forma difusa. Amb un horitzó tan llarg, l'agent té dificultats per atribuir les recompenses a les decisions que les van causar.

Aplicació al Truc

S'ha dissenyat un currículum de dues etapes:

1. **Etapla de mans** (12M passos): l'agent s'entrena en TrucGameMa, on cada mà és un episodi independent de ~ 15 passos amb recompensa densa normalitzada pts/24. La recompensa és proporcional als punts guanyats a cada mà.
2. **Etapla de partides** (12M passos addicionals): els pesos apresos es transfereixen a TrucGame, on l'episodi és una partida sencera fins a 24 punts. L'agent parteix d'una política ja formada i l'afinament es produeix sobre el comportament estratègic a llarg termini.

El risc principal és l'**oblit catastròfic**: els algorismes on-policy com PPO descarten les dades antigues, cosa que pot fer que l'agent obliidi el que va aprendre a l'etapa de mans quan s'exposa a les partides senceres. La Fase 2 avalua experimentalment fins a quin punt aquest risc es materialitza per a cada algoritme.

2.6 Deep Recurrent Q-Learning

Deep Q-Network (DQN) assumeix que l'observació o_t és una representació suficient de l'estat per prendre decisions òptimes. En un POMDP això no és cert: sense memòria de les observacions passades, l'agent pot prendre decisions subòptimes quan l'estat ocult és rellevant.

DRQN! (DRQN!) [14] proposa substituir la primera capa densa de DQN per una Gated Recurrent Unit (GRU) o **LSTM!** que manté un estat ocult (h_t, c_t) propagat a través dels passos de temps. Així, l'aproximació de la funció de valor depèn no sols de o_t sinó de tota la seqüència d'observacions passades, el que equival a aproximar la funció de valor sobre la *creença* (distribució de probabilitat sobre estats ocults).

Entrenament seqüencial

L'entrenament de **DRQN!** propaga els gradients a través del temps (BPTT, *Back-propagation Through Time*) sobre segments de trajectòria de longitud L . La pèrdua s'acumula als últims L passos de la seqüència per evitar que els gradients s'extingueixin en contextos molt llargs.

Aplicació al Truc i resultat

Per al Truc, s'han agrupat $N = 5$ mans consecutives (sessió) sense reiniciar l'estat de la **LSTM!** entre elles. La hipòtesi és que l'agent pot detectar patrons en el comportament de l'oponent al llarg de la sessió i adaptar la seva política en temps real. A la Fase 4 es prova la variant *RecurrentPPO* (LSTM sobre l'extractor CNN) combinada amb un pool de 6 variants d'oponents. Els resultats, discutits al capítol ??, revelaran limitacions importants d'aquesta aproximació en el context de recursos limitats.

2.7 Self-play i equilibri de Nash

En un joc de suma zero entre dos jugadors, un **equilibri de Nash** és un parell de polítiques (π^*, σ^*) tal que cap dels dos jugadors pot incrementar el seu retorn esperat canviant unilateralment la seva política:

$$V(\pi^*, \sigma^*) \geq V(\pi, \sigma^*) \quad \forall \pi, \quad V(\pi^*, \sigma^*) \leq V(\pi^*, \sigma) \quad \forall \sigma.$$

Una política en equilibri de Nash és *no exploitable*: cap estratègia adversària pot millorar contra ella.

Fictitious Play i self-play modern

El *Fictitious Play* (Brown, 1951) és un algorisme iteratiu on cada jugador best-responds a la política promig de l'adversari. Convergeix a l'equilibri de Nash en jocs de suma zero de dos jugadors.

El self-play modern [6] opera de manera similar: l'agent s'entrena jugant contra còpies antigues de si mateix (pool de snapshots), la qual cosa evita l'especialització excessiva contra un únic oponent i afavoreix la convergència cap a polítiques robustes.

Mètriques de robustesa

Per mesurar la qualitat de la política més enllà del win rate brut, s'han definit dues mètriques:

- $\text{metric_robust} = \overline{WR} - \lambda \sigma(WR_{\text{variant}})$, que penalitza la variança del win rate entre variants d'oponent (amb $\lambda = 0,5$).
- $\text{exploit_selfplay} = |WR_{\text{vs snapshots}} - 50|$, que mesura la distància a l'equilibri de Nash: 0 indica que cap dels dos jugadors pot guanyar sistemàticament a l'altre.

La Fase 5 implementa un pool de snapshots i confirma que la robustesa millora +18 pp sense regredir el win rate brut.

2.8 Neural Fictitious Self-Play

Neural Fictitious Self-Play (NFSP) [15] és un marc d'entrenament per a jocs d'informació imperfecta que combina l'AR per aprendre la millor resposta (*best response*) amb aprenentatge supervisat per aprendre la política promig, aproximant així l'equilibri de Nash sense resoldre explícitament l'arbre de joc.

Dos bucles en paral·lel

1. **Bucle RL (millor resposta)**: un agent PPO maximitza la recompensa jugant contra el pool d'oponents (que inclou còpies antigues i la política promig). Aquest agent aprèn una política que *best-responds* a les polítiques de l'història.
2. **Bucle SL (política promig)**: una xarxa auxiliar AveragePolicyNet s'entrena per cross-entropy per imitar les accions preses pel bucle RL al llarg de tot l'entrenament. Rep com a etiquetes les accions del bucle RL i aprèn la distribució promig d'accions.

Reservoir Buffer

Per garantir que l'estimació de la política promig sigui imparcial, les accions del bucle RL s'emmagatzemen en un *Reservoir Buffer* que aplica mostreig uniforme de l'historial: cada acció passada té la mateixa probabilitat de romandre al buffer, independentment del moment en què es va generar.

Paràmetre η i Nash gap

El paràmetre η controla la probabilitat que l'oponent jugui la política promig (SL) en lloc del pool de self-play durant l'entrenament. La distància a l'equilibri de Nash es mesura com:

$$\text{exploit_vs_sl} = |WR_{\text{PPO vs SL}} - 50|.$$

Un valor de 0 indica que el best-response i la política promig estan en equilibri: cap dels dos pot guanyar sistemàticament a l'altre. A la Fase 6, s'assoleix un Nash gap de 3,3 pp al millor checkpoint, amb un win rate màxim de 91% a 14M de passos.

CAPÍTOL 3

CONCLUSIONS

[Conclusions del treball: resum del context i del problema, principals conclusions, implicacions teòriques i pràctiques, limitacions i treball futur.]



HIPERPARÀMETRES DELS MODELS

[Taules amb els hiperparàmetres complets de cada algorisme (DQN-RLCard, NFSP-RLCard, DQN-SB3, PPO-SB3) per a cada fase experimental.]

APÈNDIX

RESULTATS COMPLETS PER FASE

[Taules amb tots els valors numèrics dels experiments: mètriques finals, temps d'entrenament, etc.]

BIBLIOGRAFIA

- [1] J. Huizinga, *Homo Ludens: A Study of the Play-Element in Culture*. Routledge & Kegan Paul, 1938. 1
- [2] M. Campbell, A. J. Hoane Jr., and F.-h. Hsu, “Deep Blue,” *Artificial Intelligence*, vol. 134, no. 1–2, pp. 57–83, 2002. 1.1
- [3] D. Silver *et al.*, “Mastering the game of Go with deep neural networks and tree search,” *Nature*, vol. 529, pp. 484–489, 2016. 1.1
- [4] C. Berner *et al.*, “Dota 2 with large scale deep reinforcement learning,” 2019, arXiv:1912.06680. 1.1
- [5] N. Brown and T. Sandholm, “Superhuman AI for heads-up no-limit poker: Libratus beats top professionals,” *Science*, vol. 359, no. 6374, pp. 418–424, 2018. 1.2, 2.2
- [6] ———, “Superhuman AI for multiplayer poker,” *Science*, vol. 365, no. 6456, pp. 885–890, 2019. 1.2, 2.2, 2.7
- [7] Retruc.net, “Reglament del truc,” <https://retruc.net/reglamenttruc>, 2024, accedit: 2026. 1.3
- [8] D. Zha, K.-H. Lai, Y. Cao, S. Huang, R. Wei, J. Guo, and X. Hu, “RLCard: A toolkit for reinforcement learning in card games,” *arXiv preprint arXiv:1910.04376*, 2019. 1
- [9] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, “Stable-baselines3: Reliable reinforcement learning implementations,” *Journal of Machine Learning Research*, vol. 22, no. 268, pp. 1–8, 2021. 1
- [10] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, 2018. 2.1
- [11] V. Mnih *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, pp. 529–533, 2015. 2.3
- [12] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017. 2.4
- [13] Y. Bengio, J. Louradour, R. Collobert, and J. Weston, “Curriculum learning,” in *Proceedings of the 26th Annual International Conference on Machine Learning (ICML)*, 2009, pp. 41–48. 2.5

- [14] M. Hausknecht and P. Stone, “Deep recurrent Q-learning for partially observable MDPs,” *arXiv preprint arXiv:1507.06527*, 2015. 2.6
- [15] J. Heinrich and D. Silver, “Deep reinforcement learning from self-play in imperfect-information games,” *arXiv preprint arXiv:1603.01121*, 2016. 2.8