



Universitat
de les Illes Balears

TREBALL DE FI DE GRAU

APRENTATGE PER REFORÇ PROFUND PER AL JOC DEL TRUC

Josep Ferriol Font

Grau d'Enginyeria Informàtica

Escola Politècnica Superior

Any acadèmic 2025-26

APRENTATGE PER REFORÇ PROFUND PER AL JOC DEL TRUC

Josep Ferriol Font

Treball de Fi de Grau

Escola Politècnica Superior

Universitat de les Illes Balears

Any acadèmic 2025-26

Paraules clau del treball: aprenentatge per reforç, truc, jocs de cartes, informació parcial, curriculum learning, self-play

Tutor: Dr. Francesc Xavier Gayà Morey

Cotutor: Dr. Gabriel Moyà Alcover

Segons estudis demogràfics, una gran part de la població mundial neix en contextos on l'accés a l'educació i la sanitat no estan garantits. Tenir la sort de néixer a Europa, en un estat de dret que reconeix la salut i l'educació com a pilars fonamentals de la societat, és un privilegi que no hauria de donar-se per descomptat. Per això, agrair haver tengut l'oportunitat de cursar una educació pública i de qualitat a la meva terra, Mallorca.

A més, un agraïment especial dirigit a la meva família, els altres grans patrocinadors d'aquesta carrera. El seu suport incondicional ha estat el fonament sobre el qual s'ha construït tot el que he aconseguit.

SUMARI

Sumari	iii
Índex de figures	v
Índex de taules	ix
Llista d'acrònims	xi
Resum	xiii
1 Introducció	1
1.1 La intel·ligència artificial en el joc	2
1.2 El repte de la informació parcial	2
1.3 El Truc: engany, parella i farol	3
1.4 Objectius i estructura d'aquest treball	3
2 Fonaments Teòrics i Treball Relacionat	5
2.1 Aprenentatge per Reforç	5
2.2 Estat de l'art en jocs d'informació parcial	9
2.3 Mètodes usats	10
2.3.1 Deep Q-Network	10
2.3.2 Proximal Policy Optimization	11
2.3.3 Recurrència i memòria: RecurrentPPO	12
2.3.4 Neural Fictitious Self-Play	12
3 El Joc del Truc	15
3.1 Regles del joc	15
3.2 Arquitectura del simulador	17
3.3 El motor de joc	20
4 Entorn d'Aprenentatge per Reforç	23
4.1 Arquitectura en capes	23
4.2 Espai d'observació	24
4.3 Espai d'accions i màscara	26
4.4 Reward shaping	26
5 Metodologia d'Entrenament	29
5.1 Marc metodològic comú	29

5.2	Bloc 1: línia base i <i>curriculum learning</i>	32
5.2.1	Fase 1: comparativa homogènia d'algorismes	32
5.2.2	Fase 2: <i>curriculum learning</i> (mà → partida)	35
5.2.3	Checkpoint 1: models seleccionats	38
5.3	Bloc 2: representació de l'estat i memòria	38
5.3.1	Fase 3: el feature extractor COS	38
5.3.1.1	Arquitectura: CNN vs MLP	38
5.3.1.2	Inicialització supervisada del COS	40
5.3.2	Fase 4: memòria d'oponent (LSTM) i pool d'oponents	42
5.3.3	Checkpoint 2: model seleccionat	46
5.4	Bloc 3: robustesa i aproximació a l'equilibri	46
5.4.1	Fase 5: <i>self-play</i> mixt i robustesa	46
5.4.2	Fase 6: Neural Fictitious Self-Play (NFSP) complet	50
5.4.3	Checkpoint 3: model de desplegament	53
6	Resultats	55
6.1	Anàlisi numèrica del model desplegat	55
6.1.1	Rendiment per oponent	55
6.1.2	Perfil d'estil emergent	56
6.1.3	Política condicionada a la força de la mà	57
6.1.4	Comportament contextual	58
6.2	Avaluació qualitativa del comportament	59
7	Conclusions	61
A	Hiperparàmetres dels models	63
B	Resultats complets per fase	65
	Bibliografia	67

ÍNDIX DE FIGURES

2.1	Cicle d'interacció agent-entorn en AR.	6
2.2	Tres arquitectures d'aproximació de la funció de valor (VFA): estimació de V , estimació de Q per a un únic parell (s, a) , i estimació simultània de Q per a totes les accions.	7
2.3	Model gràfic del POMDP: els estats s_t (cercles continus) són ocults; l'agent només observa o_t (cercles discontinus) generats per la funció d'emissió O	8
2.4	Cicle d'entrenament DQN (ordre d'execució: 1 observació, 2 acció ϵ -greedy, 3 emmagatzematge, 4 mostreig i càlcul de la pèrdua, 5 actualització de θ , 6 sincronització de θ^- cada N passos).	11
2.5	Arquitectura Actor-Critic de PPO: extractor de característiques compartit amb dos caps independents, un per a la política i un per a la funció de valor.	11
2.6	NFSP: el bucle RL genera accions que s'acumulen al reservoir buffer; el bucle SL aprèn per imitació la política promig $\bar{\pi}$, que s'usa com a oponent durant l'entrenament.	13
3.1	Arquitectura MVC: el controlador només coneix les interfícies.	18
3.2	Fases d'un torn. Sense senyes, la Fase 0 se salta. Quan es canta truc o envit, el motor entra en estat PENDING i el torn passa a l'adversari fins que respon; resoluda l'aposta, el joc reprèn la Fase 1.	21
4.1	Capas de l'entorn. TrucEnvMa i TrucGymEnvMa segueixen la mateixa estructura però amb episodi = 1 mà.	23
5.1	Win-rate ponderat (metric) de la Fase 1 sota els dos pressupostos d'entrenament. A l'esquerra, pressupost de passos (5 M passos, eficiència per mostra); a la dreta, pressupost de temps (4 hores de còmput per agent, rendiment efectiu). Cada punt és una avaluació periòdica de l'entrenament i la línia n'és la mitjana mòbil centrada. DQN-SB3 lidera en ambdós, però el rànquing de la resta canvia: PPO-SB3 és el pitjor per passos però supera DQN-RLCard i NFSP-RLCard per temps gràcies a la seva velocitat d'entrenament.	34
5.2	Curriculum de dues etapes: mans individuals amb recompensa densa, seguides de partides senceres amb transferència dels pesos apresos (θ).	35
5.3	Corbes del <i>curriculum</i> per als agents RLCard. La línia ratllada és la fase de mans (pre-entrenament); la línia sòlida el <i>finetune</i> sobre partides. La línia puntejada marca la transició als 12M passos. DQN-RLCard col·lapsa al <i>finetune</i> ; NFSP-RLCard recupera i millora lleugerament.	37

5.4	Corbes del <i>curriculum</i> per als agents SB3. DQN-SB3 assoleix un pic alt en mans (86%) però perd rendiment al <i>finetune</i> . PPO-SB3 manté el nivell i tanca a 75%, el millor resultat del treball fins al moment.	37
5.5	<i>CosMultiInput</i> : arquitectura de dues branques. La branca CNN processa el tensor de cartes (6,4,9); la branca lineal el vector de context (24,). Les sortides es concatenen i es projecten a un vector latent de 256 dimensions.	39
5.6	Pic de metric (24M passos) per protocol i agent, COS amb pesos aleatoris vs Multilayer Perceptron (MLP). La línia discontinua marca el 80%. El COS només supera clarament el MLP al control de DQN-SB3; al protocol de mans (el millor en absolut) la diferència és marginal.	40
5.7	Esquema del preentrenament supervisat: els tres caps propaguen gradient al cos i l'obliguen a aprendre representacions sensibles a l'estructura del joc. Un cop acabat, els caps es descarten i es conserven només els pesos del cos.	41
5.8	Evolució del win-rate ponderat (metric) al llarg de l'entrenament per als quatre entrenaments de la Fase 4, tallats a 12M passos. Línies discontinues: línies base de la Fase 3.5 (sense pool); línies sòlides: entrenaments amb pool; gruix adicional: model amb Long Short-Term Memory (LSTM). La línia puntejada gris marca el 85%.	43
5.9	Pic de metric per a cada run, tots tallats al pressupost comú de 12M passos. DQN frozen assoleix 87,8% dins el pressupost; el seu pic global és 91,2% a 23M passos.	44
5.10	Win-rate per posició dins la sessió (mà 1 a mà 5) per als dos runs de la Fase 4 (mitjana de les cinc darreres avaluacions). El Δ indica la diferència entre la mà 5 i la mà 1. La línia puntejada marca el 50%.	44
5.11	Composició del pool mixt al llarg del temps. Esquerra: cada fila és un instant clau; les caselles blaves (R1–R6) són les sis variants de l'agent basat en regles, sempre presents; les caselles vermelles (S1–S6) són els <i>snapshots</i> del propi agent, afegits un a un cada milió de passos. Dreta: evolució de la proporció de self-play, que passa de 0% al pas 0 fins al 50% quan el pool és ple (pas 6M en endavant).	48
5.12	Evolució de la metric (esquerra) i la metric_robust (dreta) al llarg de 48M passos. Línia discontinua: F4-ablació-48M (sense self-play); línia sòlida: F5-selfplay. La metric és pràcticament idèntica (H1), però la metric_robust de F5 creix de forma sostenuda i supera àmpliament la de F4 (H2).	48
5.13	Win-rate per variant d'oponent (models seleccionats). F4 (blau) mostra una distribució irregular: alt contra l'estil conservador i equilibrat, baix contra l'agressiu i el faroler. F5 (vermell) reequilibra la distribució: puja tots els valors baixos al 80–85% al preu d'abaixar l'estil conservador (la variació inversa és el senyal que la política ja no s'especialitza).	49
5.14	Corbes principals de F6-NFSP en tres panells: metric, metric_robust i std_{pool} , amb F5-selfplay com a referència discontinua. El warm-start accelera el pic inicial de metric, però la robustesa i la dispersió mostren estabilització més lenta fins a l'aturada anticipada als 20M passos.	52
5.15	Panell esquerre: trajectòria del <i>Nash gap</i> empíric (<i>exploit_vs_sl</i>) amb llin-dar de 8 pp. Panell dret: evolució de la calibració estratègica (<i>calib_envit</i> , <i>calib_truc</i> i <i>calib_combined</i>).	52

6.1	Win-rate del model desplegat contra cada oponent. Domina tots els estils del pool i empata contra si mateix.	56
6.2	Perfil d'estil emergent del model (vermell) comparat amb l'agent basat en regles equilibrat (blau), sobre cinc eixos normalitzats. El model és molt més agressiu al truc i mai no es retira, però obre envit menys que l'Aprenentatge per Reforç (AR).	57
6.3	Política condicionada. A dalt: probabilitat de cada acció segons la força de la mà (esquerra) i els punts d'envit (dreta). A baix: distribució de la força de la mà i dels punts d'envit per a cada acció.	58
6.4	Comportament contextual. Esquerra: distribució d'accions per número de ronda dins la mà. Dreta: agressió (% d'apostes de truc i d'envit) segons la situació al marcador.	59

ÍNDIX DE TAULES

2.1	Components de la tupla MDP.	6
2.2	Característiques principals dels algorismes d'AR emprats al treball.	10
3.1	Jerarquia de força de les cartes, de major a menor.	16
3.2	Escala d'apostes de l'Envit i punts cedits en cas de retirada.	17
3.3	Escala d'apostes del Truc.	17
3.4	Mètodes principals del contracte Model.	18
3.5	Mètodes principals del contracte Vista.	19
4.1	Els sis canals del tensor de cartes obs_cartes.	25
4.2	Les 24 dimensions del vector de context obs_context.	25
5.1	Les sis variants de l'agent basat en regles que formen el <i>pool</i> d'oponents (Fases 4–6). La variant equilibrada (primera fila) reproduïx el comportament per defecte usat a les fases 1–3.	31
5.2	Els quatre algorismes comparats a la Fase 1.	32
5.3	Distribució d'oponents per episodi a la Fase 1. Els agents de RLCard incorporen self-play; els de Stable-Baselines3 (SB3) entrenen només contra oponents fixos (l'agent aleatori i l'agent basat en regles), sense self-play.	33
5.4	Win-rate ponderat (metric) de la Fase 1 sota les dues òptiques. «Millor» és el pic durant l'entrenament; «Final» és el valor en acabar, que evidencia la inestabilitat.	34
5.5	Velocitat d'entrenament dels quatre algorismes. El paral·lelisme de PPO-SB3 el fa 28 vegades més ràpid que NFSP-RLCard.	34
5.6	Comparació a 12M passos (mateix pressupost, avaluació sobre partides). El win-rate ponderat (metric) entrenant sobre mans és uniformement superior.	36
5.7	Comparació a 24M passos totals (control sencer vs curriculum complet). Només PPO-SB3 i NFSP-RLCard milloren; DQN-RLCard col·lapsa per oblit catastròfic.	36
5.8	Pic de metric (24M passos) per a COS amb pesos aleatoris vs MLP.	40
5.9	Caps de predicció del <i>ModelPreEntrenament</i> per al preentrenament supervisat del cos <i>CosMultiInput</i>	41
5.10	Pic de metric (protocol mans, 24M passos) per als quatre règims d'inicialització del cos.	42
5.11	Resultats de la Fase 4 (pressupost igualat a 12M passos). DQN frozen mostra el seu màxim dins el pressupost de 12M; el seu pic global és del 91,2% a 23M.	45

5.12	Resum de la Fase 5 (pressupost de 48M passos). F5 iguala la metric clàssica i supera la robustesa en 4,6 punts.	49
5.13	Win-rate per variant del pool: F4-ablació vs F5-selfplay (models seleccionats). El self-play apuja tots els valors baixos i redueix la dispersió; el descens contra l'estil conservador és el reequilibri esperat.	49
5.14	Comparativa F4/F5/F6 amb mètriques de rendiment i criteris Nash. F6 assoleix Nash genuí però no redueix la dispersió inter-estil respecte a F5.	52
5.15	Candidats de desplegament de la Fase 6, avaluats amb 1000 partides balancejades contra les 6 variants del pool. Criteri primari: Nash gap exploit_vs_sl < 8 pp (tots passen). Desempat: metric_robust màxima, on destaca best_nash (64,4%).	53
6.1	Rendiment del model desplegat per oponent (500 partides balancejades cadascun).	56

LLISTA D'ACRÒNIMS

AR	Aprenentatge per Reforç
CNN	Convolutional Neural Network
DQN	Deep Q-Network
DRL	Deep Reinforcement Learning
DRQN	Deep Recurrent Q-Network
GRU	Gated Recurrent Unit
IA	Intel·ligència Artificial
LSTM	Long Short-Term Memory
MDP	Markov Decision Process
MLP	Multilayer Perceptron
MVC	Model-Vista-Controlador
NFSP	Neural Fictitious Self-Play
POMDP	Partially Observable Markov Decision Process
PPO	Proximal Policy Optimization
SB3	Stable-Baselines3
SL	Supervised Learning
TFG	Treball Final de Grau

RESUM

[Resum de 250–500 paraules: problema, mètode, resultats, conclusions.]

Paraules clau: *reinforcement learning, truc, jocs de cartes, DQN, PPO, NFSP, informació parcial, curriculum learning, self-play.*

INTRODUCCIÓ

El joc és una de les activitats més antigues de la humanitat. Més que un objecte d'estudi, és una pràctica social: un espai on les persones s'enfronten, es coordinen, negocien i, sovint, s'ensenyen mútuament. Els antropòlegs el descriuen com un mecanisme de transmissió cultural i d'entrenament de la intel·ligència, present en totes les societats conegudes [1]. Jugar no és només passar l'estona: és **practicar la presa de decisions sota incertesa, gestionar el risc i llegir les intencions dels altres**.

Els jocs tradicionals hi afegeixen una capa de patrimoni i cultura. Aquests no són simples entreteniments: són codis culturals transmesos de generació en generació, amb vocabulari propi, rituals i regles que reflecteixen el pensament social de cada territori. El problema és que necessiten jugadors que coincideixin al mateix lloc i al mateix moment. La dispersió geogràfica, l'envelliment dels cercles de jugadors i el canvi d'hàbits d'oci fan que sigui cada cop més difícil. Sense adversaris ni parella, **el joc s'extingeix per inanició, no per desinterès**.

No record exactament quan vaig aprendre a jugar a cartes. Als tretze o catorze anys ja hi jugaven tots els meus amics del poble. El que sé és que he tengut la sort de poder comptar amb els padrins, ties i altra gent, que m'han pogut ensenyar els distints jocs tradicionals, entre ells jocs de cartes. Al meu poble, jocs com el Terceti (que avui quasi ja no es juga a cap altre lloc) o el Truc formen part de la vida quotidiana, transmesos de generació en generació sense que ningú ho pensés gaire.

Però amb els anys m'he anat adonant que cada cop és més difícil trobar gent per seure a una taula. El cercle de jugadors envelleix, i quan no hi ha prou persones disponibles el Truc simplement no es pot jugar. Aquesta inquietud és el que m'ha duit a fer aquest Treball Final de Grau (TFG): crear una versió del Truc que es pugui jugar contra un agent d'aprenentatge per reforç, de manera que **el joc pugui continuar viu encara que no hi hagi quatre humans disponibles**.

1.1 La intel·ligència artificial en el joc

Darrerament, la relació entre jocs i Intel·ligència Artificial (IA) ha anat més lluny de la preservació cultural. Des de fa dècades, els jocs han servit també com a banc de prova per als investigadors, ja que, en ser entorns tancats amb regles precises i un criteri d'èxit mesurable, permeten avaluar algorismes de manera objectiva i reproducible. L'any 1997, Deep Blue va derrotar el campió mundial d'escacs Garry Kasparov, una fita que semblava inalcançable una dècada abans [2]. El 2016, AlphaGo va superar Lee Sedol al joc del Go, un problema considerat exponencialment més complex pels seus 10^{170} estats possibles [3]. El 2019, l'agent OpenAI Five va derrotar equips professionals de Dota 2 en partides de cinc jugadors per banda [4].

El denominador comú d'aquests avenços és el Deep Reinforcement Learning (DRL): la combinació de l'AR clàssic amb xarxes neuronals profundes. L'AR permet a un agent aprendre interactuant amb un entorn i rebent recompenses; les xarxes profundes li permeten representar espais d'estats molt complexos sense necessitat de definir manualment les característiques rellevants. La combinació dels dos ha permès que **agents sense cap coneixement inicial arribin a nivells humans** en diferents dominis (escacs, Go, Dota 2, etc.). Aquest treball segueix el mateix enfocament: xarxes neuronals profundes combinades amb AR per aprendre a jugar al Truc partint de zero.

1.2 El repte de la informació parcial

Tots aquests èxits, però, es produeixen en jocs d'*informació completa*: tots els jugadors veuen l'estat sencer del joc en tot moment. Els escacs, el Go i els jocs de taulell en general pertanyen a aquesta categoria. En canvi, molts dels jocs que els humans troben més fascinants, i estratègicament rics, amaguen informació: les cartes dels adversaris, les intencions futures, els recursos ocults.

Formalment, un joc d'informació parcial es modela com un Partially Observable Markov Decision Process (POMDP): l'agent rep observacions parcials de l'estat real del món i ha d'actuar sense visibilitat completa. L'estratègia òptima ja no consisteix a calcular la millor jugada donada la posició, sinó a **raonar sobre els estats ocults i el possible comportament d'un adversari**.

Els jocs de pòquer han estat el principal camp d'experimentació en informació parcial. El 2017, Libratus va guanyar jugadors professionals de Texas Hold'em de dos jugadors (*heads-up*) [5]. El 2019, Pluribus va estendre aquest resultat al pòquer de sis jugadors, un entorn multiagent molt més complex on les tècniques clàssiques de teoria de jocs no escalen directament [6]. Ambdós agents aproximen un *equilibri de Nash*: una estratègia tal que cap jugador pot millorar el seu resultat canviant unilateralment de política.

Malgrat aquests progressos, el camp és lluny d'estar tancat. Cada joc d'informació parcial té la seva pròpia estructura d'observació, el seu espai d'accions i les seves dinàmiques estratègiques. Un agent entrenat al pòquer no es pot transferir directament a un altre joc de cartes: cal dissenyar l'entorn, definir l'espai d'estats i triar els algorismes adequats a cada cas.

1.3 El Truc: engany, parella i farol

El Truc és un joc de cartes tradicional d'arrel catalana i valenciana, arrelat a les Illes Balears i al País Valencià [7]. Es juga per parelles (dos contra dos) amb una baralla espanyola de 36 cartes, i guanya el primer equip que arriba als 24 punts d'una *cama*. Cada mà es disputa en dues apostes independents: l'**Envit** (sobre la força de la mà en punts) i el **Truc** (sobre qui guanya les rondes de carta alta). Les regles completes, la jerarquia de cartes i el model formal es detallen al capítol 3.

La mecànica no és el que fa del Truc un repte per a la IA. És el **farol**: qui té cartes dolentes pot cantar Truc amb convicció i guanyar el punt sense ensenyar-les. A més, les parelles es coordinen mitjançant *senyes*, un sistema de gestos facials codificats que els adversaris poden intentar llegir i explotar. Com es diu al joc: *"El Truc no és només matemàtiques i memòria. És un joc de cares, de silencis i de mentides."*

Tot plegat, el Truc és un POMDP cooperatiu-competitiu: l'agent ha de gestionar informació oculta, coordinar-se sense comunicació verbal explícita i decidir a cada torn si enganyar o ser sincer sobre la força de la seva mà. Aquesta combinació de factors el fa substancialment diferent dels jocs estudiats fins ara en la literatura.

1.4 Objectius i estructura d'aquest treball

L'objectiu d'aquest TFG és desenvolupar i avaluar agents d'AR capaços de jugar al Truc de manera competitiva, partint de zero i sense cap coneixement previ del joc. L'entrenament dels agents es circumscriu a la variant d'1 vs 1 sense senyes; l'extensió a agents cooperatius per parelles s'identifica (2 vs 2 amb senyes) com a línia de recerca futura. Per assolir aquest objectiu, el treball es desglossa en tres subobjectius:

1. **Modelització, implementació i aplicació jugable.** Dissenyar i implementar un simulador del Truc que implementi totes les regles del joc (envit, truc i apostes), oferir un mode de joc jugador contra agent, i exposar el simulador com a entorn estàndard compatible amb les biblioteques d'AR existents. El motor admet també la variant 2 vs 2 amb senyes, tot i que l'entrenament d'agents es limita a 1 vs 1.
2. **Comparació d'algorismes i tècniques d'entrenament.** Avaluar quatre algorismes (Deep Q-Network (DQN) i Neural Fictitious Self-Play (NFSP) via RLCARD, i DQN i Proximal Policy Optimization (PPO) via SB3) en condicions homogènies, i estudiar l'efecte del *curriculum learning* (entrenar primer en mans individuals i després en partides senceres), de l'ús d'extractors de característiques convolucionals, de la memòria recurrent i del *self-play* sobre la convergència i el rendiment dels agents.
3. **Avaluació.** Mesurar el rendiment de cada agent contra un agent de regles heurístiques i analitzar si els agents aprenen comportaments estratègics (gestió de l'envit, ús del farol al truc) o es limiten a polítiques reactives.

El treball s'organitza de la manera següent. El capítol 2 presenta el marc teòric: els fonaments de l'AR, els algorismes emprats i l'estat de l'art en jocs d'informació parcial. El capítol 3 descriu la lògica del joc i l'arquitectura del simulador. El capítol 4 detalla el

1. INTRODUCCIÓ

disseny dels entorns d'AR. El capítol 5 explica la metodologia d'aprenentatge per reforç i les fases d'entrenament. El capítol 6 presenta i discuteix els resultats experimentals. Finalment, el capítol ?? recull les conclusions i les línies de treball futur.

FONAMENTS TEÒRICS I TREBALL RELACIONAT

Aquest capítol estableix el marc conceptual del treball en tres blocs. Primer presenta els fonaments de l'AR. A continuació revisa l'estat de l'art en jocs d'informació parcial, que justifica l'elecció d'un enfocament basat en DRL. Finalment descriu els algorismes i tècniques concrets que s'utilitzen a la part experimental.

2.1 Aprenentatge per Reforç

L'AR és el paradigma d'aprenentatge automàtic en el qual un agent aprèn a actuar en un entorn mitjançant la interacció directa, guiat per senyals de recompensa [8]. A diferència de l'aprenentatge supervisat, no existeix cap conjunt d'exemples etiquetats ni un tercer que indiqui la resposta correcta; a diferència de l'aprenentatge no supervisat, sí que hi ha una senyal d'avaluació (la recompensa) que orienta l'aprenentatge.

Aquesta secció presenta els fonaments formals de l'AR: la formalització com a MDP, les funcions de valor i les equacions de Bellman, el dilema exploració-explotació, la distinció entre algorismes *on-policy* i *off-policy*, l'extensió al cas d'observació parcial (POMDP) i el concepte d'equilibri de Nash en jocs multi-agent.

Procés de Decisió de Markov

L'entorn es formalitza com un Markov Decision Process (MDP), definit per la tupla (S, A, P, R, γ) on cada component té el significat que recull la Taula 2.1.

Component	Descripció
S	Conjunt d'estats de l'entorn
A	Conjunt d'accions disponibles per a l'agent
$P(s' s, a)$	Probabilitat de transitar a s' prenent l'acció a des de s
$R(s, a, s')$	Recompensa immediata esperada en la transició
$\gamma \in [0, 1)$	Factor de descompte (recompenses futures vs. immediates)

Taula 2.1: Components de la tupla MDP.

El nom fa referència a la **propietat de Markov**: l'estat s_t conté tota la informació necessària per prendre la decisió òptima, de manera que el futur és independent del passat donat el present:

$$P(s_{t+1} | s_t, a_t) = P(s_{t+1} | s_0, a_0, \dots, s_t, a_t).$$

Això implica que l'agent no necessita recordar els estats anteriors: n'hi ha prou amb l'estat actual per calcular la millor acció.

Una *política* π és la regla de decisió de l'agent: en la forma estocàstica, $\pi(a | s)$ expressa la probabilitat de seleccionar l'acció a quan l'estat és s ; en la forma determinista, $\pi : S \rightarrow A$ assigna directament una acció a cada estat. El cicle bàsic d'interacció és el representat a la Figura 2.1: a cada pas de temps t , l'agent observa s_t , tria $a_t \sim \pi(\cdot | s_t)$, rep la recompensa r_t i l'entorn transita a $s_{t+1} \sim P(\cdot | s_t, a_t)$.




Figura 2.1: Cicle d'interacció agent-entorn en AR.

L'objectiu de l'agent és trobar la política òptima π^* que maximitzi el *retorn acumulat descomptat*:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}.$$

El factor γ controla l'horitzó temporal efectiu: quan $\gamma \rightarrow 0$ l'agent és miop i prioritza les recompenses immediates; quan $\gamma \rightarrow 1$ valora el futur quasi tant com el present.

Funcions de valor i equacions de Bellman

Per saber si una política π és bona, cal quantificar el retorn esperat que l'agent obtindrà seguint-la. Per fer-ho s'utilitzen dues funcions de valor complementàries: la *funció de valor d'estat* $V^\pi(s)$ i la *funció de valor d'acció* $Q^\pi(s, a)$:

$$V^\pi(s) = \mathbb{E}_\pi[G_t | s_t = s], \quad Q^\pi(s, a) = \mathbb{E}_\pi[G_t | s_t = s, a_t = a].$$

Aquestes funcions satisfan les *equacions de Bellman*, que les expressen de forma recursiva a partir del pas immediatament següent:

$$V^\pi(s) = \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V^\pi(s')], \quad (2.1)$$

$$Q^\pi(s, a) = \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma \sum_{a'} \pi(a' | s') Q^\pi(s', a')]. \quad (2.2)$$

Quan la política és l'òptima π^* , les equacions es simplifiquen substituint la suma sobre accions per un màxim:

$$V^*(s) = \max_a \mathbb{E}[r + \gamma V^*(s') | s, a], \quad (2.3)$$

$$Q^*(s, a) = \mathbb{E}[r + \gamma \max_{a'} Q^*(s', a') | s, a]. \quad (2.4)$$

La relació entre totes dues és $V^*(s) = \max_a Q^*(s, a)$, i la política òptima s'obté directament com $\pi^*(s) = \operatorname{argmax}_a Q^*(s, a)$.

Aproximació de la funció de valor

Calcular Q^* en la pràctica requereix representar el valor de cada parell (s, a) possible. En entorns petits amb estats discrets n'hi ha prou amb una **taula de consulta** on cada entrada emmagatzema $Q(s, a)$ individualment. El problema és que en la majoria d'entorns reals l'espai d'estats és exponencialment gran: ni s'hi pot emmagatzemar tota la taula en memòria, ni és viable aprendre un valor independent per a cada estat.

La solució és substituir la taula per un **aproximador de funcions** $\hat{Q}(s, a; \mathbf{w})$ parametritzat per un vector de pesos $\mathbf{w}$ que *generalitza* entre estats similars. L'aproximador rep com a entrada l'estat (o el parell estat-acció) i estima el valor Q corresponent. Hi ha tres arquitectures habituals, il·lustrades a la Figura 2.2:




Figura 2.2: Tres arquitectures d'aproximació de la funció de valor (VFA): estimació de V , estimació de Q per a un únic parell (s, a) , i estimació simultània de Q per a totes les accions.

La tercera arquitectura —entrada s , sortida un valor Q per a cada acció possible— és la més eficient per a la presa de decisions, ja que permet comparar totes les accions amb una sola passada per la xarxa. És l'arquitectura que utilitza DQN. L'ús de **xarxes neuronals profundes** com a aproximador és el que dóna nom a la família DRL: l'agent aprèn els pesos $\mathbf{w}$ d'una xarxa $Q(s, a; \mathbf{w})$ que aproxima la funció de valor òptima, en lloc d'una taula.

Exploració i explotació

Fins i tot amb les equacions de Bellman ben definides, aprendre Q^* per interacció directa planteja un dilema pràctic: l'agent ha de decidir si aplica l'acció que creu millor (**explotació**) o en prova una de nova per obtenir més informació (**exploració**). Sense exploració suficient, l'agent queda atrapat en polítiques subòptimes; amb massa exploració, no convergeix.

L'estratègia ε -greedy és la solució més senzilla: amb probabilitat $1 - \varepsilon$ tria l'acció de valor màxim i amb probabilitat ε n'escull una uniformement a l'atzar. Durant l'entrenament, ε decau des d'un valor proper a 1 fins a un valor residual baix. Els algorismes de gradient de política com PPO adopten un enfocament diferent: afegeixen un terme d'entropia $\mathcal{H}[\pi]$ a la funció objectiu, penalitzant les polítiques massa deterministes i incentivant la diversitat d'accions de forma contínua.

Polítiques *on-policy* i *off-policy*

Els algorismes *on-policy* aprenen exclusivament de transicions generades per la política que s'està optimitzant en cada moment: les dades queden obsoletes tan bon punt la política s'actualitza. Els algorismes *off-policy*, en canvi, separen la política que genera experiència (*política de comportament*) de la que s'optimitza (*política objectiu*), de manera que les transicions passades poden ser reutilitzades per a múltiples actualitzacions. Aquesta distinció implica compromisos diferent entre estabilitat d'entrenament i eficiència de mostres.

Observació parcial: el model POMDP

Els models MDP vistos fins ara assumeixen que l'agent observa l'estat complet del sistema en cada instant. En molts entorns reals, i en particular al Truc, aquesta suposició no es compleix: els adversaris amaguen les seves cartes i les intencions futures romanen ocultes.

Un POMDP estén el MDP amb dues components addicionals (un conjunt d'observacions Ω i una funció d'emissió O), donant la tupla completa $(S, A, P, R, \gamma, \Omega, O)$. La funció $O(o | s', a)$ especifica la probabilitat de rebre l'observació $o \in \Omega$ després de transitar a l'estat s' prenent l'acció a . L'agent no veu s_t directament, sinó una observació parcial o_t que en conté menys informació, tal com il·lustra la Figura 2.3.




Figura 2.3: Model gràfic del POMDP: els estats s_t (cercles continus) són ocults; l'agent només observa o_t (cercles discontinus) generats per la funció d'emissió O .

La política òptima en un POMDP ha de raonar sobre la *distribució de creença* (*belief state*) $b_t(s) = P(s_t = s \mid o_{1:t}, a_{1:t-1})$. Quan es rep una nova observació o_{t+1} , la creença s'actualitza aplicant el teorema de Bayes:

$$b_{t+1}(s') \propto O(o_{t+1} \mid s', a_t) \sum_{s \in S} P(s' \mid s, a_t) b_t(s).$$

En la pràctica, mantenir b_t explícitament és intractable per a espais d'estats grans. En el seu lloc s'utilitzen xarxes recurrents (LSTM, GRU) que comprimeixen l'historial d'observacions en un vector d'estat ocult, actuant com a representació implícita de la creença.

L'entorn del Truc és precisament un POMDP: l'agent rep una observació que inclou la seva mà i l'historial d'apostes visible, però no les cartes dels adversaris.

Equilibri de Nash

En els jocs multi-agent, el criteri d'optimitat ja no és maximitzar una recompensa contra un entorn fix, sinó respondre bé a un adversari que també optimitza. En un joc de suma zero entre dos jugadors, un **equilibri de Nash** és una parella de polítiques (π^*, σ^*) tal que cap dels dos jugadors pot incrementar el seu retorn esperat canviant unilateralment la seva política:

$$V(\pi^*, \sigma^*) \geq V(\pi, \sigma^*) \quad \forall \pi, \quad V(\pi^*, \sigma^*) \leq V(\pi^*, \sigma) \quad \forall \sigma.$$

Una política en equilibri de Nash és *no explotable*: cap estratègia adversària pot millorar sistemàticament contra ella. Aproximar aquest equilibri és l'objectiu dels mètodes de self-play i NFSP descrits més endavant.

2.2 Estat de l'art en jocs d'informació parcial

El pòquer ha estat el banc de prova principal per a la IA en jocs d'informació parcial. L'estat de l'art actual és la família d'algorismes basats en Minimització del Penediment Contra-factual (*Counterfactual Regret Minimization*, CFR), que han assolit rendiment sobrehumà de forma consistent [5, 6].

El 2017, Brown i Sandholm [5] presentaren **Libratus**, que guanya jugadors professionals de Texas Hold'em de dos jugadors. CFR minimitza iterativament el penediment contra-factual (la millora hipotètica si s'hagués pres una acció diferent) i convergeix a l'equilibri de Nash. Libratus resol sub-jocs en temps real per refinar la seva estratègia durant la partida.

El 2019, els mateixos autors proposaren **Pluribus** [6], que estén aquest resultat al pòquer de sis jugadors combinant Monte Carlo CFR, una estratègia de base (*blueprint*) obtinguda per self-play i la resolució de sub-jocs en temps real. Pluribus fou la primera IA a superar humans en un entorn multi-jugador d'informació parcial.

Malgrat els seus èxits, CFR presenta tres limitacions que motiven l'ús de DRL en aquest treball. El cost creix exponencialment amb la profunditat de l'arbre i el nombre de jugadors, cosa que exigeix abstraccions manuals específiques per a cada joc. A més, aquestes abstraccions no es transfereixen: redissenyar-les per al Truc (amb

apostes menys estructurades i senyes) seria tan costós com el problema original. Finalment, CFR no aprèn representacions compartides, de manera que no es beneficia de la generalització de les xarxes neuronals.

L'enfocament DRL (DQN, PPO, NFSP) evita modelar l'arbre explícitament i generalitza a nous jocs sense redissenyar abstraccions, a canvi d'una convergència a Nash menys garantida teòricament.

2.3 Mètodes usats

Aquesta secció descriu els algorismes i tècniques d'AR que s'empren a la part experimental del treball, des dels algorismes base fins als marcs de self-play. La taula 2.2 ofereix una visió de conjunt.

Taula 2.2: Característiques principals dels algorismes d'AR emprats al treball.

Algorisme	Família	On/Off-policy	Memòria
DQN [9]	Aprox. funcions de valor	Off-policy	Experience replay
PPO [10]	Actor-crític	On-policy	Cap
NFSP [11]	Fictitious self-play	Tots dos	Reservoir buffer

2.3.1 Deep Q-Network

DQN [9] fou el primer algoritme de DRL a demostrar rendiment comparable al humà en entorns d'alta dimensionalitat. L'agent s'entrenà directament des de fotogrames crus del joc (píxels en escala de grisos), sense cap característica dissenyada manualment, combinant Q-learning amb xarxes neuronals profundes. Va assolir rendiment aproximadament humà en una cinquantena de jocs Atari i sobrehumà en molts d'altres, la qual cosa demostrà que les xarxes neuronals podien aprendre representacions útils per al control directament des de la percepció bruta [9].

En lloc d'una taula $Q(s, a)$, DQN aproxima la funció de valor d'acció amb una xarxa neuronal $Q(s, a; \theta)$ parametritzada per θ . Aprèn minimitzant la pèrdua:

$$\mathcal{L}(\theta) = \mathbb{E}_{(s, a, r, s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right].$$

Dues innovacions clau estableixen l'entrenament:

- **Experience Replay:** les transicions (s, a, r, s') s'emmagatzemen en un buffer $\mathcal{D}$ i es mostregen aleatòriament. Això trenca la correlació temporal entre mostres consecutives, requisit per a la convergència de la xarxa.
- **Xarxa objectiu θ^- :** una còpia de θ que s'actualitza periòdicament (cada N passes) i s'usa per calcular els objectius de Bellman. Evita l'oscil·lació causada per actualitzar simultàniament la xarxa d'estimació i l'objectiu.




Figura 2.4: Cicle d'entrenament DQN (ordre d'execució: 1 observació, 2 acció ϵ -greedy, 3 emmagatzematge, 4 mostreig i càlcul de la pèrdua, 5 actualització de θ , 6 sincronització de θ^- cada N passos).

2.3.2 Proximal Policy Optimization

PPO [10] és un algoritme Actor-Critic on-policy que s'ha convertit en l'estàndard pràctic de l'AR gràcies a la seva estabilitat i eficiència computacional.

Actor-Critic

PPO manté dues xarxes: l'*actor* $\pi(a | s; \theta)$, que parametriza la política i aprèn a seleccionar la millor acció; i el *crític* $V(s; \phi)$, que parametriza la funció de valor i estima el retorn esperat des de l'estat actual. Ambdues xarxes comparteixen un extractor de característiques comú i divergeixen en dos caps independents (Figura 2.5). L'actor usa la valoració del crític com a referència: si una acció és millor del que el crític esperava, l'actor la reforça; si és pitjor, la penalitza. Aquesta guia redueix la incertesa de l'aprenentatge.

L'avantatge estimat $\hat{A}_t$ mesura si l'acció escollida és millor o pitjor del que preveia el crític, i s'estima mitjançant el mètode GAE (*Generalized Advantage Estimation*).




Figura 2.5: Arquitectura Actor-Critic de PPO: extractor de característiques compartit amb dos caps independents, un per a la política i un per a la funció de valor.

Objectiu amb retall

La innovació central de PPO és l'objectiu amb retall (*clipped surrogate objective*), que limita l'actualització de la política per evitar passos massa grans:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t [\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)],$$

on $r_t(\theta) = \pi(a_t | s_t; \theta) / \pi(a_t | s_t; \theta_{\text{old}})$ és el ràtio entre la política nova i l'antiga, i $\epsilon = 0,2$.

La pèrdua total afegeix un terme de valor $\mathcal{L}^V$ i un bonus d'entropia $\mathcal{H}[\pi]$ per mantenir l'exploració:

$$\mathcal{L} = \mathcal{L}^{\text{CLIP}} - c_1 \mathcal{L}^V + c_2 \mathcal{H}[\pi].$$

2.3.3 Recurrència i memòria: RecurrentPPO

Els mètodes vistos fins ara (DQN, PPO) assumeixen que l'observació o_t és una representació suficient de l'estat per prendre decisions òptimes. En un POMDP com el Truc això no és cert: sense memòria de les observacions passades, l'agent pot prendre decisions subòptimes quan l'estat ocult és rellevant.

Per dotar l'agent de memòria s'afegeix una capa recurrent (com la Gated Recurrent Unit (GRU) o la LSTM) que manté un estat ocult (h_t, c_t) propagat a través dels passos de temps. Així, la política ja no depèn només de o_t sinó de tota la seqüència d'observacions passades, el que equival a actuar sobre la *creença* (distribució de probabilitat sobre estats ocults). Aplicada al PPO, aquesta extensió és el *RecurrentPPO*.

La idea d'afegir recurrència per a tractar un POMDP prové del Deep Recurrent Q-Network (DRQN) [12], que la va introduir sobre el DQN; aquí se n'aplica el mateix principi al PPO.

L'entrenament propaga els gradients a través del temps (BPTT, *Backpropagation Through Time*) sobre segments de trajectòria de longitud L . La pèrdua s'acumula als últims L passos de la seqüència per evitar que els gradients s'extingeixin en contextos molt llargs.

2.3.4 Neural Fictitious Self-Play

Self-play i Fictitious Play

Aproximar l'equilibri de Nash (definit a la secció 2.1) requereix entrenar contra adversaris cada cop més forts en lloc d'un oponent fix. El self-play aconsegueix precisament això fent que l'agent jugui contra si mateix.

El *Fictitious Play* [13] és un algorisme iteratiu on cada jugador respon amb la millor acció possible a la política promig de l'adversari. Convergeix a l'equilibri de Nash en jocs de suma zero de dos jugadors.

El self-play modern [6] opera de manera similar: l'agent s'entrena jugant contra captures de pesos anteriors (*snapshots*), la qual cosa evita l'especialització excessiva contra un únic oponent i afavoreix la convergència cap a polítiques robustes. La robustesa i l'explotabilitat d'aquestes polítiques es quantifiquen amb mètriques específiques que es defineixen al capítol 5.

De Fictitious Play a NFSP

NFSP [11] duu el Fictitious Play al cas neuronal: és un marc d'entrenament per a jocs d'informació imperfecta que combina l'AR per aprendre la millor resposta (*best response*) amb aprenentatge supervisat per aprendre la política promig, aproximant així l'equilibri de Nash sense resoldre explícitament l'arbre de joc.

Dos bucles en paral·lel

1. **Bucle RL (millor resposta)**: un agent PPO maximitza la recompensa jugant contra el pool d'oponents (que inclou còpies antigues i la política promig). Aquest agent aprèn una política que respon amb la millor acció possible a les polítiques de l'història.
2. **Bucle SL (política promig)**: una xarxa auxiliar *AveragePolicyNet* s'entrena per cross-entropy per imitar les accions preses pel bucle RL al llarg de tot l'entrenament. Rep com a etiquetes les accions del bucle RL i aprèn la distribució promig d'accions.




Figura 2.6: NFSP: el bucle RL genera accions que s'acumulen al reservoir buffer; el bucle SL aprèn per imitació la política promig $\bar{\pi}$, que s'usa com a oponent durant l'entrenament.

Reservoir Buffer

Per garantir que l'estimació de la política promig sigui imparcial, les accions del bucle RL s'emmagatzemen en un *Reservoir Buffer* que aplica mostreig uniforme de l'història: cada acció passada té la mateixa probabilitat de romandre al buffer, independentment del moment en què es va generar.

Paràmetre η

El paràmetre η controla la probabilitat que l'oponent jugui la política promig (SL) en lloc del pool de self-play durant l'entrenament. La distància a l'equilibri (*Nash gap*) es mesura comparant la millor resposta amb la política promig: si cap de les dues pot guanyar sistemàticament a l'altra, el sistema és a prop de l'equilibri. La mètrica concreta es defineix al capítol 5.

EL JOC DEL TRUC

Abans d'entrenar cap agent cal disposar d'una implementació fidel i verificable del joc. Aquest capítol presenta primer les regles del Truc en la variant considerada, i tot seguit l'arquitectura de programari que les materialitza: un disseny Model-Vista-Controlador (MVC) que separa la lògica del joc, el control del flux i la interfície amb l'usuari. Aquesta separació és la que permet, més endavant, connectar el mateix motor de joc tant a una interfície humana com als entorns d'AR (capítol 4).

3.1 Regles del joc

El Truc és un joc de bases i apostes que es juga per parelles (dos contra dos) o un contra un. L'objectiu és ser el primer equip a assolir els 24 punts d'una *cama*. Es fa servir la baralla espanyola reduïda a 36 cartes: dels quatre colls (Ors, Copes, Espases i Bastos) s'eliminen els 2, 8 i 9, de manera que cada coll conserva nou rangs: {1, 3, 4, 5, 6, 7, 10, 11, 12}.

Jerarquia de les cartes

A diferència d'altres jocs, el valor de combat de les cartes no segueix l'ordre numèric. La taula 3.1 recull la jerarquia completa tal com la implementa el jutge del joc (TrucJutger): les quatre cartes superiors són úniques i reben noms propis, mentre que la resta s'ordena per rang amb desempats entre colls.

3. EL JOC DEL TRUC

Posició	Carta	Denominació
1	11 de Bastos	L'Amo
2	10 d'Ors	Sa Madona
3	As d'Espases	L'espasa
4	As de Bastos	El basto
5	7 d'Espases	Manilla
6	7 d'Ors	Manilla
7	Els tresos	(cap)
8	Assos d'Ors i de Copes	Assos bords
9	Els dotzes	Figures
10	Els onzes	Figures
11	Els deus	Figures
12	7 de Bastos i de Copes	Sets bords
13	Els sisos	
14	Els cincs	Blanques
15	Els quates	

Taula 3.1: Jerarquia de força de les cartes, de major a menor.

Cada mà es reparteix amb tres cartes per jugador i es disputa en dues apostes independents que es resolen per separat: **l'Envit i el Truc**.

L'Envit

L'Envit és l'aposta sobre la força de la mà en punts, i **els jugadors només ho poden cantar a la primera ronda, abans de jugar la seva primera carta**. El valor d'una mà es calcula sumant els valors de les dues cartes més altes d'un mateix coll i afegint-hi 20 punts base, si hi ha dues cartes del mateix coll. A efectes d'aquesta suma, les figures (10, 11 i 12) valen 0, amb dues excepcions: el 10 d'Ors compta 7 i l'11 de Bastos compta 8, i tots dos lliguen amb qualsevol coll. Alguns exemples:

- 7 i 6 d'Espases: $7 + 6 + 20 = 33$ punts.
- As i 5 de Copes: $1 + 5 + 20 = 26$ punts.
- 11 de Bastos i 3 d'Ors: $8 + 3 + 20 = 31$ punts (el 11 de Bastos compta 8 i lliga amb Ors).
- Tres cartes de colls distints (p. ex. 7 d'Ors, 6 de Copes i As de Bastos): no hi ha cap parella del mateix coll, de manera que el jugador no té envit però ho pot cantar igualment com a farol.

Si cap equip canta envit durant la mà, no es disputa cap punt d'envit. Un cop cantat, l'equip contrari pot acceptar, contra-apostar o retirar-se. La retirada cedeix sempre **el valor acumulat fins al moment**: si un equip ha acceptat l'*Envit* (2 pts en joc) i l'adversari canta *Un altre*, retirar-se en aquest punt cedeix 2 punts, no 1 com passaria si rebutgis un *Envit*. Cada crit incrementa els punts en joc segons la taula 3.2. En cas d'empat de

puntuació, guanya l'equip que és **mà** (el jugador que juga immediatament després del qui ha repartit).

Crit	Punts en joc	Si et retires
Envit	2	1 pt
Un altre	4	2 pts (el nivell anterior acceptat)
Dos més	6	4 pts
La Falta	punts que falten al líder	6 pts

Taula 3.2: Escala d'apostes de l'Envit i punts cedits en cas de retirada.

El Truc

El Truc és l'aposta sobre qui guanya les cartes. La mà es resol en fins a tres rondes (anomenades *bassetges*): a cada ronda els jugadors juguen una carta i en guanya la de rang superior segons la taula 3.1; l'equip que s'endú dues bassetges guanya la mà. En qualsevol moment un jugador pot cantar *Truc*, obrint una escala d'apostes independent de l'Envit (taula 3.3). Com en l'Envit, el contrari pot acceptar, contra-apostar o retirar-se cedint el nivell anterior. Els empats es resolen de la manera següent: si la primera ronda acaba en empat, la guanya qui s'imposi a la segona; si és la segona la que empata, puntua qui havia guanyat la primera; si empaten totes dues primeres rondes i la tercera també acaba en empat, guanya l'equip que és **mà**.

Crit	Punts en joc
Truc	3
Retruc	6
Quatre Val	9
Joc Fora	tota la cama

Taula 3.3: Escala d'apostes del Truc.

Les senyes

En la modalitat per parelles, els companys es comuniquen mitjançant *senyes*: un conjunt de nou gestos facials codificats que indiquen quines cartes fortes es tenen, sense parlar i procurant que els rivals no els vegin. Per exemple, alçar les celles indica que es té L'Amo, i aclucar un ull, Sa Madona. La implementació recull aquests nou senyals com a accions del joc, però el seu ús queda restringit a les partides 2 contra 2 entre humans; l'entrenament dels agents es fa sobre la variant 1 contra 1 sense senyes (vegeu el capítol 5).

3.2 Arquitectura del simulador

El simulador segueix el patró MVC, que separa el sistema en tres responsabilitats independents:

- El **model** conté la lògica del joc: l'estat, les regles i els jugadors automàtics.
- La **vista** gestiona l'entrada i la sortida amb l'usuari.
- El **controlador** orquestra el flux, demanant dades i accions a la vista i consultant i modificant l'estat a través del model.

La clau del disseny és que el controlador no depèn de cap implementació concreta, sinó de dues *interfícies* (contractes): qualsevol vista i qualsevol model que les satisfacin són intercanviables sense tocar el controlador. Aquesta indirecció és la que permet reutilitzar el mateix nucli de joc tant per a una interfície gràfica humana com per als adaptadors d'AR. La figura 3.1 resumeix aquesta organització.




Figura 3.1: Arquitectura MVC: el controlador només coneix les interfícies.

Els contractes

El controlador interactua amb el model mitjançant el protocol `Model` i amb la vista mitjançant el protocol `Vista`, tots dos definits als fitxers d'interfície respectius. Les taules 3.4 i 3.5 en resumeixen els mètodes principals.

Mètode	Funció
<code>iniciar(config)</code>	Crea i inicialitza una partida
<code>get_estat(pid)</code>	Retorna l'estat visible per a un jugador
<code>get_jugador_actual()</code>	Indica qui ha de jugar ara
<code>es_huma(pid)</code>	Indica si el jugador és humà
<code>get_accio_bot(pid)</code>	Retorna l'acció triada per un bot
<code>aplicar_accio(a)</code>	Aplica una acció i avança l'estat
<code>get_guanyador_envit_recent()</code>	Retorna equip, punts i detall de l'envit tancat
<code>get_guanyador_truc_recent()</code>	Retorna equip i punts del truc tancat
<code>es_final()</code>	Indica si la partida ha acabat
<code>get_resultat()</code>	Retorna el marcador i els <i>payoffs</i> finals

Taula 3.4: Mètodes principals del contracte `Model`.

Mètode	Funció
<code>demanar_config()</code>	Demana la configuració de la partida
<code>mostrar_estat(estat)</code>	Mostra l'estat actual del joc
<code>escollir_accio(legals, estat)</code>	Presenta les accions legals i en retorna una
<code>mostrar_accio(pid, nom, bot)</code>	Informa de l'acció feta (bot afegeix retard visual)
<code>mostrar_guanyador_envit(...)</code>	Comunica qui ha guanyat l'envit de la mà
<code>mostrar_guanyador_truc(...)</code>	Comunica qui ha guanyat el truc
<code>mostrar_fi_partida(...)</code>	Mostra el resultat final
<code>demanar_repetir()</code>	Pregunta si es vol jugar una altra partida
<code>mostrar_sortint()</code>	Indica que l'usuari surt de l'aplicació

Taula 3.5: Mètodes principals del contracte Vista.

El bucle de joc

El controlador implementa un bucle únic que avança mentre la partida no acabi (algorisme 1). A cada iteració consulta qui té el torn; si és un humà, mostra l'estat i li demana una acció per la vista i l'aplica al model; si és un bot, obté l'acció directament del model i l'aplica. Després de cada jugada comunica a la vista els esdeveniments rellevants (qui ha guanyat l'envit o el truc) i, en acabar, mostra el resultat. La propietat clau és la separació de responsabilitats: tota la lògica de joc resta al model, tota la presentació resta a la vista, i el controlador es limita a coordinar-los sense conèixer els detalls interns de cap dels dos.

Algorisme 1 Bucle principal de joc gestionat pel controlador.

- 1: obtenir la configuració de la partida i inicialitzar el model
 - 2: **mentre** la partida no ha acabat **fer**
 - 3: $j \leftarrow$ jugador a qui correspon el torn
 - 4: **si** j és humà **llavors**
 - 5: mostrar a la vista l'estat visible per j
 - 6: $a \leftarrow$ acció triada per l'usuari entre les legals
 - 7: **si no**
 - 8: $a \leftarrow$ acció decidida pel jugador automàtic
 - 9: **fi si**
 - 10: aplicar a al model i avançar l'estat del joc
 - 11: comunicar a la vista l'acció i els esdeveniments que se'n deriven
 - 12: **fi mentre**
 - 13: mostrar a la vista el marcador i el resultat final
-

Entre el controlador i el motor hi ha un adaptador que compleix el contracte del model: embolcalla el motor de joc (TrucGame) i hi afegeix la capacitat d'assignar a cada jugador automàtic qualsevol política, des d'un agent aleatori fins a una xarxa neuronal entrenada. Gràcies a aquesta indirecció, substituir el rival per un agent d'AR no exigeix cap canvi ni al controlador ni a la resta del motor.

Les interfícies

El projecte ofereix dues vistes plenament funcionals. La **vista de consola** és una interfície de text, lleugera i adequada per a execucions automàtiques i depuració en entorns sense pantalla. La **vista d'escriptori** és una interfície gràfica que representa l'estat amb imatges reals de cartes i recull les accions per clic de ratolí, intercalant retards artificials en els moviments dels bots per emular el ritme d'un rival humà. La interfície gràfica permet jugar partides 1 contra 1 (humà contra humà o humà contra agent) i 2 contra 2 entre humans amb suport de senyes.

3.3 El motor de joc

El cor del model és la classe `TrucGame`, que gestiona tot l'estat de la partida (jugadors, cartes, apostes, rondes i puntuació) de manera independent de qualsevol interfície. Delega responsabilitats concretes en tres rols especialitzats, cadascun en un mòdul independent: `TrucDealer` barreja i reparteix les cartes; `TrucJudger` resol la jerarquia, els guanyadors de rondes i el càlcul de l'envit; i `TrucPlayer` representa cada jugador, mantenint la mà actual, la mà inicial (necessària per resoldre l'envit encara que les cartes ja s'hagin jugat) i, opcionalment, el model que decideix les seves accions.

Accions i estat de resposta

El conjunt d'accions del joc és fix i consta de 19 accions: tres per jugar cada carta de la mà, set per a apostes i respostes, i nou per a les senyes. Les accions d'aposta es divideixen per joc: per a l'Envit, `apostar_envit`, `vull_envit` i `fora_envit`; per al Truc, `apostar_truc`, `vull_truc`, `fora_truc` i `passar`. Acceptació i rebuig existeixen per separat: `fora_envit` no clou la mà (el joc continua sense puntuar l'envit), mentre que `fora_truc` implica retirar-se i cedeix els punts en joc. En cada torn, el motor restringeix les accions legals segons la situació.

Un mecanisme central és l'*estat de resposta* (enum `ResponseState`), que pot prendre tres valors: `NO_PENDING`, `TRUC_PENDING` i `ENVIT_PENDING`. Mentre hi ha una aposta pendent, l'adversari només pot acceptar-la, contra-apostar-la o retirar-se: no pot jugar cartes ni fer cap altra acció fins que l'aposta es resolgui. De manera anàloga, quan l'envit queda resolt els punts no s'afegeixen immediatament al marcador sinó que queden suspesos fins que el truc de la mà es tanca, de manera que el marcador reflecteix sempre una mà completament decidida.

Les fases del torn

Per eficiència en l'entrenament, l'estat d'un torn s'ha reduït a dues fases (figura 3.2). La **Fase 0** (senyals) només existeix quan les senyes estan actives i permet registrar un gest abans de jugar; si estan desactivades, se salta completament. La **Fase 1** unifica apostes i joc de cartes: és on es canta l'envit o el truc, es responen les apostes i es juguen les cartes.




Figura 3.2: Fases d'un torn. Sense senyes, la Fase 0 se salta. Quan es canta truc o envit, el motor entra en estat PENDING i el torn passa a l'adversari fins que respon; resoluda l'aposta, el joc reprèn la Fase 1.

Fi de mà i fi de partida

El motor distingeix dos nivells de finalització, tots dos implementats al motor de joc. La funció `is_ma_over` indica que la mà actual ha acabat (perquè hi ha un guanyador per rondes o perquè algú s'ha retirat), moment en què es reparteixen els punts i es reparteix una mà nova. La funció `is_over` indica que la partida sencera ha acabat, quan un equip arriba a la puntuació final de la cama.

A banda del resultat final de la partida, el motor emet senyals de recompensa intermèdia (`reward_intermedis`) després de cada jugada rellevant, que s'inclouen dins l'estat retornat a cada pas. El disseny detallat d'aquestes recompenses es descriu al capítol 4.

ENTORN D'APRENENTATGE PER REFORÇ

Per entrenar agents d'AR al Truc cal adaptar el motor de joc a la interfície estàndard que esperen les biblioteques d'AR. Aquesta adaptació no és trivial: el motor gestiona el torn de múltiples jugadors, manté un estat intern ric i emet senyals de recompensa que les biblioteques genèriques no entenen de manera nativa. Aquest capítol descriu com s'ha organitzat aquesta adaptació en capes, quines decisions s'han pres per representar l'observació i les accions, i com s'ha dissenyat el sistema de recompenses.

4.1 Arquitectura en capes

L'entorn s'organitza en dos nivells d'abstracció superposats (figura 4.1):

1. **Capa RLCard** (TrucEnv / TrucEnvMa): fa de pont entre el motor de joc i el món de l'AR. Tradueix l'estat intern del motor en observacions estructurades, determina quines accions són legals a cada pas i recull les trajectòries completes de la partida.
2. **Capa Gymnasium** (TrucGymEnv / TrucGymEnvMa): adapta la capa anterior a la interfície estàndard de Gymnasium (reinici i pas) perquè les biblioteques d'Stable-Baselines3 (SB3) la puguin entrenar sense saber res del Truc. A més, fa transparent el torn del rival (avança el joc fins que torna a tocar a l'agent aprenent) i acumula les recompenses intermèdies.




Figura 4.1: Capes de l'entorn. TrucEnvMa i TrucGymEnvMa segueixen la mateixa estructura però amb episodi = 1 mà.

La distinció entre `TrucEnv` i `TrucEnvMa` rau en la granularitat de l'episodi: `TrucEnv` fa córrer una partida completa fins als 24 punts (centenars de passos), mentre que `TrucEnvMa` atura l'episodi quan acaba la mà actual (entre 6 i 20 passos aproximadament). Aquesta variant és clau per al *curriculum learning*: l'agent aprèn primer a gestionar mans individuals i posteriorment s'enfronta a partides senceres. El detall del curriculum es descriu al capítol 5.

A més d'aquests dos parells, hi ha dues variants especialitzades:

- **Entorn de sessió** (*TrucGymEnvSessio*): l'episodi agrupa N mans consecutives contra el mateix oponent (per defecte $N = 5$), que es selecciona del *pool* a l'inici de cada episodi. En no reiniciar l'estat entre mans, obliga l'agent a acumular context al llarg de la sessió i li dona l'oportunitat de detectar el patró de joc del rival. S'usa a la Fase 4 (memòria entre mans amb *RecurrentPPO*).
- **Entorn paral·lel**: executa diverses instàncies de l'entorn per mà en processos separats i en recull les trajectòries (amb les recompenses intermèdies) al procés principal. Permet col·lectar dades de molts episodis simultàniament, cosa que accelera l'entrenament propi de NFSP.

L'entorn permet, a més, substituir el rival en calent sense reconstruir-lo. Aquesta capacitat és imprescindible perquè els mecanismes d'entrenament puguin anar canviant d'oponent durant una mateixa execució, tal com requereixen el *pool* d'oponents i el *curriculum learning*.

4.2 Espai d'observació

L'observació que rep l'agent en cada pas combina dues representacions complementàries:

- `obs_cartes`: tensor de forma (6, 4, 9), que codifica en format *one-hot* la presència de cada carta en sis canals semàntics.
- `obs_context`: vector de 24 valors reals que recull informació numèrica de l'estat de la partida.

Junts representen l'estat observable del joc en 240 dimensions. La funció `flatten_obs` és l'única font de veritat per a la conversió a vector `pla`:

$$\mathbf{o} = [\text{obs_cartes.flatten()} \parallel \text{obs_context}] \in \mathbb{R}^{216+24} = \mathbb{R}^{240}. \quad (4.1)$$

Qualsevol codi que necessiti el vector `pla` (algoritmes SB3, NFSP, avaluació) crida aquesta funció per garantir coherència.

Tensor de cartes (6, 4, 9)

Les dimensions del tensor corresponen a: eix 0 = canal semàntic (6), eix 1 = pal (4: Espases, Copes, Ors, Bastos), eix 2 = rang (9: {1, 3, 4, 5, 6, 7, 10, 11, 12}). Cada cel·la val 1 si la carta corresponent hi és present i 0 altrament.

Canal	Contingut	Descripció
0	Mà actual	Cartes que té l'agent a la mà
1	Historial propi	Cartes que ja ha jugat l'agent
2	Historial Rival 1	Cartes jugades pel rival de la dreta
3	Historial Company	Cartes jugades pel company (2v2)
4	Historial Rival 2	Cartes jugades pel segon rival (2v2)
5	Senyes company	Cartes revelades per les senyes del company

Taula 4.1: Els sis canals del tensor de cartes `obs_cartes`.

Els índexs de canal 1–4 s'assignen de manera relativa al jugador actual: l'offset k correspon al jugador $(id + k) \bmod n$, de manera que la mateixa estructura de tensor és vàlida per a qualsevol posició de la taula i per a les modalitats 2v2 i 1v1.

Vector de context (24 dimensions)

Índex(os)	Significat	Rang	Codificació
0	Puntuació equip propi	$[0, 1]$	$p_{\text{propi}}/24$
1	Puntuació equip rival	$[0, 1]$	$p_{\text{rival}}/24$
2	Nivell aposta de Truc	$[0, 1]$	$\text{level}_{\text{truc}}/24$
3	Nivell aposta d'Envit	$[0, 1]$	$\text{level}_{\text{envit}}/24$
4	Fase del torn	$\{0, 1\}$	0 = senyes, 1 = apostes/joc
5	Ronda actual	$[0, 1]$	$\text{ronda}/\text{cartes_jugador}$
6–9	Qui és <i>mà</i>	$\{0, 1\}^4$	One-hot relatiu a l'agent
10–13	Qui ha cantat Truc	$\{0, 1\}^4$	One-hot relatiu; 0 si no s'ha cantat
14–16	Qui ha cantat Envit	$\{0, 1\}^3$	One-hot relatiu; 0 si no s'ha cantat
17	Rondes guanyades (propi)	$[0, 1]$	$r_{\text{propi}}/3$
18	Rondes guanyades (rival)	$[0, 1]$	$r_{\text{rival}}/3$
19	Guanyador ronda 1	$\{-1, 0, 1\}$	+1 = propi, -1 = rival, 0 = empat
20	Guanyador ronda 2	$\{-1, 0, 1\}$	+1 = propi, -1 = rival, 0 = empat
21	Envit acceptat	$\{0, 1\}$	Binari
22	Truc pendent	$\{0, 1\}$	1 si TRUC_PENDING
23	Envit pendent	$\{0, 1\}$	1 si ENVIT_PENDING

Taula 4.2: Les 24 dimensions del vector de context `obs_context`.

Totes les variables s'expressen de manera relativa a la perspectiva de l'agent actual. Això fa que el tensor sigui invariant a la posició de la taula: no cal cap transformació addicional per canviar de jugador.

Aquest vector de 240 dimensions és l'entrada de la xarxa de l'agent. L'arquitectura concreta de l'extractor de característiques que el processa (en particular la comparació entre un Multilayer Perceptron (MLP) pla i un extractor convolucional que respecta l'estructura $6 \times 4 \times 9$ del tensor de cartes) es tracta al capítol 5.

4.3 Espai d'accions i màscara

L'espai d'accions conté 19 accions discretes, definides al capítol 3. No totes elles són legals en tot moment: si hi ha un Truc pendent, l'agent només pot respondre (vull, fora o contra); si s'estan jugant cartes no pot apostar si ja ha apostat abans en la mateixa mà, etc.

A cada pas, l'entorn calcula el conjunt d'accions vàlides segons la situació i el posa a disposició de l'algorisme de dues maneres complementàries:

- **Correcció d'accions il·legals:** si el model tria una acció que no és vàlida (cosa habitual a les primeres fases, quan la política és gairebé aleatòria), l'entorn la reemplaça per una acció legal en lloc de generar un error. Així l'entrenament mai no s'interromp per una jugada invàlida.
- **Màscara explícita:** amb els algorismes que ho admeten (com el PPO amb màscara d'accions de SB3), el conjunt legal es passa directament a la política perquè assigni probabilitat zero a les accions il·legals.

En jocs amb apostes encadenades com el Truc, la màscara és especialment important: sense ella, l'agent podria intentar re-apostar quan ja no és possible, o respondre a una aposta que ja ha estat resolta. La separació entre les accions definides al motor i les legals en cada pas permet que el motor mantingui la lògica de negoci sense barrejar-la amb la política de l'agent.

4.4 Reward shaping

En una partida fins a 24 punts, la recompensa final pot trigar centenars de passos a arribar. Sense senyals intermèdies, l'agent sabria si ha guanyat o perdut però no podria atribuir el resultat a cap acció concreta: el problema d'assignació de crèdit fa que aprendre a gestionar l'envit o a forçar el truc sigui pràcticament impossible en condicions de recompensa escassa. La solució és el *reward shaping*.

Recompensa terminal

Quan acaba la partida (o la mà, en la variant de gra fi) l'entorn lliura la recompensa terminal:

- **TrucEnv (partida completa):** +1,0 per a l'equip guanyador, -1,0 per al perdedor.
- **TrucEnvMa (mà individual):** $\pm \text{punts}/24$, on *punts* són els punts de la mà (Truc + Envit). Normalitzar per 24 manté la recompensa a l'escala de la partida completa.

Recompenses intermèdies

El motor associa a cada transició una recompensa intermèdia que reflecteix el resultat immediat de l'acció. El tractament difereix segons la capa. A la capa RLCard, que per disseny deixa totes les transicions intermèdies a zero, un postprocés recorre la trajectòria un cop acabat l'episodi i substitueix aquests zeros pel valor acumulat de

l'equip, deixant intacte el *payoff* final. A la capa Gymnasium, en canvi, la recompensa intermèdia s'extreu i s'aplica directament a cada pas, amplificada per un factor 5:

$$r_t = \text{reward_intermedis}[\text{equip}] \times 5,0. \quad (4.2)$$

El factor 5 equilibra l'escala entre els senyals intermedis (ordre de 0.1–0.5) i la recompensa terminal (± 1.0), donant suficient pes al feedback immediat sense eclipsar l'objectiu final.

Les recompenses intermèdies que emet el motor es desglossen de la manera següent:

- **Guanyar una ronda:** $+0,40 \times w_r$ per al guanyador i $-0,20 \times w_r$ per al perdedor, on w_r és un pes decreixent per ronda ($w_1 = 2,0$, $w_2 = 1,0$, $w_3 = 0,5$) que reflecteix que les primeres rondes són més determinants. Si perdre la ronda implica perdre la mà, la penalització s'amplifica per un factor 1,5.
- **Envit acceptat:** recompensa proporcional als punts en joc per a l'equip que matemàticament guanya l'envit.
- **Envit rebutjat (fora_envit):** $+1,5 \times$ per a l'equip que força el rebuig, $-1,0 \times$ per al que es retira.
- **Truc rebutjat (fora_truc en resposta):** $+1,5 \times$ per a l'agressiu, $-1,0 \times$ per al retirat.
- **Retirada voluntària (fora_truc sense resposta pendent):** $+1,0 \times$ per a l'oponent, $-1,2 \times$ per al que fuig, per penalitzar les fugides injustificades.
- **Guanyar la mà (truc net):** $\pm 1,0 \times$ el factor base.

La variant per mans simplifica el sistema: acumula un únic reward net al final de cada mà com $\pm$ punts/24, sense senyals de ronda individuals. Això afavoreix un aprenentatge més estable per a la fase de *curriculum learning* on cada episodi és una única mà.

METODOLOGIA D'ENTRENAMENT

Aquest capítol descriu el procés experimental que ha portat des d'agents incapaços de batre una heurística senzilla fins a un agent competitiu. L'enfocament és incremental: cada fase planteja una hipòtesi concreta, dissenya un experiment per validar-la, n'analitza els resultats i pren una decisió que condiciona la fase següent. Aquesta estructura (*hipòtesi* → *disseny* → *resultats* → *decisió*) permet aïllar l'efecte de cada tècnica i justificar per què el treball avança en una direcció i no en una altra.

Les fases s'agrupen en tres blocs. Els dos primers es tanquen amb un punt de control (*checkpoint*) que fixa quins models continuen; el tercer culmina amb la decisió del model de desplegament:

- **Bloc 1** (secció 5.2): línia base comparativa i *curriculum learning* (Fases 1–2, Checkpoint 1).
- **Bloc 2** (secció 5.3): representació de l'estat i memòria (Fases 3, 3.5 i 4, Checkpoint 2).
- **Bloc 3** (secció 5.4): robustesa i aproximació a l'equilibri (Fases 5–6), amb la decisió final del model de desplegament.

5.1 Marc metodològic comú

Totes les fases comparteixen el mateix protocol d'avaluació, la mateixa mètrica i el mateix oponent de referència. Aquesta secció els defineix una vegada per no repetir-los a cada fase.

Protocol d'avaluació

El rendiment d'un agent es mesura amb la funció `evaluar_agent()`, que juga un nombre fix de partides senceres contra dos oponents de referència: 100 partides contra

un agent aleatori (l'agent aleatori) i 100 partides contra l'agent basat en regles (l'agent basat en regles). Per evitar el biaix posicional (ser *mà* dona un lleuger avantatge), l'agent alterna la seva posició (jugador 0 i jugador 1) en partides consecutives. L'avaluació es fa cada 500 000 passos d'entrenament i sempre sobre **partides senceres**, encara que l'agent s'estigui entrenant sobre mans individuals; així es mesura sempre la competència real al joc complet.

Mètrica de rendiment

S'ha triat el *win-rate* (percentatge de partides guanyades) com a base de la mètrica, en lloc de la recompensa acumulada, per tres motius: és l'objectiu últim del joc, és directament interpretable i és comparable entre algorismes diferents. Aquest darrer punt és el més important. La recompensa d'entrenament de PPO i la de DQN no són directament comparables perquè cada algorisme optimitza una quantitat interna distinta: PPO maximitza un objectiu de gradient de política sobre l'avantatge estimada, mentre que DQN minimitza l'error de diferència temporal de la seva funció Q (secció 2.3.1 i secció 2.3.2). El win-rate, en canvi, és una mètrica *externa*: es calcula jugant partides i comptant victòries, amb independència de com s'ha entrenat l'agent, i per això permet comparar qualsevol parella d'algorismes en igualtat de condicions. La mètrica combina el win-rate contra dos oponents complementaris:

$$\text{metric} = 0,25 \cdot \text{wr}_{\text{random}} + 0,75 \cdot \text{wr}_{\text{regles}}. \quad (5.1)$$

Cada terme compleix una funció diferent. L'agent basat en regles (pes 0,75) és l'oponent **discriminant**: batre una heurística coherent requereix estratègia real, de manera que aquest terme és el que captura la qualitat de l'agent. L'agent aleatori (pes 0,25) actua com a **xarxa de seguretat**: guanyar-li és trivial, però un agent que no hi guanyi de manera clara revela un col·lapse de la política (per exemple, una política degenerada que repeteix sempre la mateixa acció). Aquest terme detecta degeneracions que el win-rate contra regles, per si sol, podria emascarar. El pes dominant recau, doncs, sobre l'oponent que de debò discrimina l'habilitat, mentre que el terme aleatori aporta un sòl d'estabilitat. Les fases avançades (5 i 6) introdueixen mètriques addicionals de robustesa i explotabilitat, que es defineixen al bloc corresponent.

L'oponent de referència: l'agent basat en regles

L'agent basat en regles és un agent heurístic codificat a mà que serveix alhora com a oponent d'entrenament i d'avaluació. No té cap xarxa neuronal: la seva política prové d'heurístiques amb llindars adaptatius sobre la força de la mà, els punts d'envit i el marcador.

La variant equilibrada i els seus paràmetres. El comportament base de l'agent (la variant *equilibrada*) està governat per quatre paràmetres, cadascun amb un valor neutre que es pren com a referència. Cada paràmetre modula un aspecte de la política:

- `envit_agressio` (neutre 1,0): escala els llindars de punts per acceptar o apujar l'envit. Amb el valor neutre, l'agent apuja l'envit a partir de 30 punts de mà i l'accepta a partir de 25; el paràmetre divideix aquests llindars, de manera que un

valor més alt els abaixa (accepta amb mans més febles) i un de més baix els apuja (més conservador). Els llindars també s'ajusten segons el marcador: si el rival és a punt de guanyar la partida, l'agent es torna conservador; si l'envit pot donar-li la partida, es torna agressiu.

- `truc_agressio` (neutre 1,0): probabilitat d'apostar el truc en situacions favorables (per exemple, havent guanyat una ronda i amb una carta alta). Amb 1,0 aposta sempre en aquests casos; valors menors el fan dubtar i valors majors hi afegeixen farols addicionals.
- `farol_prob` (neutre 0,12): probabilitat d'apostar el truc *sense* una mà forta, és a dir, de fer farol.
- `resposta_truc` (neutre 1,0): disposició a acceptar un truc cantat pel rival. Ajusta el llindar de força exigida per acceptar: valors superiors a 1 accepten amb menys mà, valors inferiors es retiren més sovint.

Estocasticitat. La característica clau de l'agent és que és **estocàstic**: sobre les decisions deterministes anteriors hi injecta soroll aleatori (± 2 punts als llindars d'envit, ± 5 al llindar de força del truc, i decisions probabilístiques a les zones grises de cada llindar). Aquesta estocasticitat és deliberada i essencial. Un oponent purament determinista seria fàcilment explotable: l'agent d'AR aprendria a predir-ne les respostes fixes i el batria de manera artificial, inflant la mètrica sense reflectir cap habilitat real (*reward hacking* contra un oponent fix). El soroll obliga l'agent entrenat a generalitzar i fa de l'agent basat en regles una barrera molt més exigent del que sembla.

El pool de variants. A partir de la Fase 4, els quatre paràmetres es modifiquen per generar sis **variants** amb estils de joc contrastats, que formen un *pool* d'oponents (taula 5.1): des de la conservadora (poc agressiva i gairebé sense farol) fins a la farolera (màxima probabilitat de farol), passant per especialistes en truc o en envit. La variant equilibrada hi figura amb els valors neutres descrits més amunt.

Variant	<code>truc_agressio</code>	<code>envit_agressio</code>	<code>farol_prob</code>	<code>resposta_truc</code>
Equilibrat	1,0	1,0	0,12	1,0
Conservador	0,5	0,5	0,02	0,6
Agressiu	1,8	1,8	0,30	1,5
Truc-bot	2,0	0,4	0,15	1,2
Envit-bot	0,4	2,0	0,05	0,7
Faroler	1,3	1,3	0,40	1,3

Taula 5.1: Les sis variants de l'agent basat en regles que formen el *pool* d'oponents (Fases 4–6). La variant equilibrada (primera fila) reproduïx el comportament per defecte usat a les fases 1–3.

Convencions comunes

Llevat que s'indiqui el contrari, tots els agents comparteixen l'arquitectura base de xarxa (MLP de dues capes ocultes de 256 unitats amb ReLU) i s'avaluen sobre l'observa-

ció de 240 dimensions descrita al capítol 4. El pressupost d'entrenament s'expressa en *timesteps* (passos d'interacció amb l'entorn). Els hiperparàmetres complets de cada algorisme i fase es recullen a l'annex A; al cos del capítol només se'n destaquen els rellevants per a cada decisió.

5.2 Bloc 1: línia base i *curriculum learning*

El primer bloc estableix un punt de partida (Fase 1) i introdueix la primera tècnica que trenca el sostre de rendiment inicial (Fase 2, *curriculum learning*). El Checkpoint 1 tanca el bloc seleccionant els dos models que continuen.

5.2.1 Fase 1: comparativa homogènia d'algorismes

Hipòtesi. Abans d'aplicar cap tècnica avançada cal saber quin algorisme parteix amb avantatge. La Fase 1 compara quatre algorismes d'AR en igualtat de condicions i partint de zero, sense cap coneixement previ del joc.

Disseny. Es comparen quatre agents que cobreixen les dues grans famílies d'algorismes d'AR: els **basats en la funció de valor** (com el DQN, que aprèn quant val cada acció i n'extreu la política) i els **basats en el gradient de la política** (com el PPO, que optimitza directament la política). Es reparteixen també entre les variants *on-policy* i *off-policy* (definides al capítol 2) i entre les dues biblioteques emprades (taula 5.2). Tots comparteixen la mateixa observació de 240 dimensions, la mateixa arquitectura MLP de [256, 256] sense extractor convolucional, i la mateixa funció d'avaluació; així qualsevol diferència s'atribueix a l'algorisme i no a l'arquitectura.

Algorisme	Biblioteca	Política	Paral·lisme
DQN-RLCard	RLCard	Off-policy	1 entorn seqüencial
NFSP-RLCard	RLCard	Off-policy + SL	1 entorn seqüencial
DQN-SB3	SB3	Off-policy	1 entorn
PPO-SB3	SB3	On-policy	48 entorns (<i>SubprocVecEnv</i>)

Taula 5.2: Els quatre algorismes comparats a la Fase 1.

Dos entrenaments per agent: pressupost de passos i pressupost de temps. Com que els algorismes tenen velocitats molt diferents, comparar-los amb un únic criteri d'aturada seria injust amb els paral·lelitzables. Per això cada agent s'entrena **dues vegades**, un entrenament independent per a cada pressupost:

- **Pressupost de passos** (5 milions): l'entrenament s'atura en assolir el mateix nombre de passos, amb independència del temps que hi dediqui cada algorisme. Mesura l'eficiència per mostra.
- **Pressupost de temps** (4 hores per agent): l'entrenament s'atura en exhaurir el mateix temps de còmput, amb independència dels passos que hi càpiguen. Mesura el rendiment efectiu segons la velocitat d'entrenament.

Oponents. Cada agent s'entrena contra una barreja d'oponents (taula 5.3) amb un criteri comú: una petita fracció de partides contra l'agent aleatori (per mantenir diversitat i explorar estats poc habituals) i el gruix contra l'agent basat en regles (el senyal estratègic principal). La diferència és el *self-play*: els agents de RLCard (DQN i NFSP) el suporten de manera nativa, de manera que un 30% de les partides es juguen contra una versió del propi agent, en canvi, els agents de SB3 no incorporen *self-play*. En el cas del DQN, aquesta versió és una còpia *Polyak* que s'actualitza lentament (un 5% cap als pesos actuals cada 5 000 passos): així l'oponent millora amb l'agent però no canvia tan de pressa com per desestabilitzar l'aprenentatge.

Agent	Random	l'agent basat en regles	Self-play
DQN-RLCard	10%	60%	30% (Polyak)
NFSP-RLCard	10%	60%	30% (natiu)
DQN-SB3	5%	95%	—
PPO-SB3	5%	95%	—

Taula 5.3: Distribució d'oponents per episodi a la Fase 1. Els agents de RLCard incorporen *self-play*; els de SB3 entrenen només contra oponents fixos (l'agent aleatori i l'agent basat en regles), sense *self-play*.

Bucle d'entrenament. Els dos agents de RLCard s'entrenen amb un bucle manual: controla el format de cada transició que s'injecta al *replay buffer*, alterna la posició de l'aprenent a cada partida i resol l'assignació de crèdit quan és l'oponent qui tanca la partida (la recompensa terminal s'assigna a la darrera jugada de l'aprenent). Els agents SB3 usen la rutina nativa de la biblioteca amb un *callback* que avalua i desa el millor model cada 500 000 passos. PPO genera l'experiència amb 48 entorns en paral·lel repartits entre oponents i posicions. Per garantir que l'avaluació mesura generalització i no memorització, l'agent basat en regles de l'avaluació s'instancia amb una llavor diferent de la d'entrenament.

Resultats. Cap agent assoleix un rendiment alt i estable alhora (taula 5.4). DQN-SB3 és el millor en totes dues òptiques (pic del 62,8% per passos i 58,5% per temps), però pateix una degradació severa cap al final de l'entrenament (de 62,8% a 36,5%): la seva millor mètrica és molt superior a la final. PPO-SB3 és el més feble a igualtat de passos (29,5%), perquè un algorisme on-policy necessita molts més passos per estabilitzar-se, però té una velocitat d'entrenament incomparable (taula 5.5): genera 36,5 milions de passos per hora, 28 vegades més que NFSP. Aquest contrast fa que el rànquing canviï entre els dos pressupostos (figura 5.1). El patró comú a tots els agents és la **inestabilitat**: regredeixen cap al final de l'entrenament, senyal que el problema (partida llarga, recompensa molt diferida) no proporciona un senyal d'aprenentatge prou estable.

5. METODOLOGIA D'ENTRENAMENT

Agent	Per passos (5M)		Per temps (4 h)	
	Millor	Final	Millor	Final
DQN-SB3	62,8%	36,5%	58,5%	17,2%
NFSP-RLCard	53,2%	29,0%	43,0%	33,2%
DQN-RLCard	51,0%	25,8%	44,5%	34,2%
PPO-SB3	29,5%	18,5%	42,0%	21,2%

Taula 5.4: Win-rate ponderat (metric) de la Fase 1 sota les dues òptiques. «Millor» és el pic durant l'entrenament; «Final» és el valor en acabar, que evidencia la inestabilitat.

Algorisme	Passos/hora	Factor vs NFSP
PPO-SB3	36,5 M	28×
DQN-SB3	7,0 M	5,4×
DQN-RLCard	5,5 M	4,2×
NFSP-RLCard	1,3 M	1×

Taula 5.5: Velocitat d'entrenament dels quatre algorismes. El paral·lelisme de PPO-SB3 el fa 28 vegades més ràpid que NFSP-RLCard.




Figura 5.1: Win-rate ponderat (metric) de la Fase 1 sota els dos pressupostos d'entrenament. A l'esquerra, pressupost de passos (5 M passos, eficiència per mostra); a la dreta, pressupost de temps (4 hores de còmput per agent, rendiment efectiu). Cada punt és una avaluació periòdica de l'entrenament i la línia n'és la mitjana mòbil centrada. DQN-SB3 lidera en ambdós, però el rànquing de la resta canvia: PPO-SB3 és el pitjor per passos però supera DQN-RLCard i NFSP-RLCard per temps gràcies a la seva velocitat d'entrenament.

Decisió. El coll d'ampolla no és el còmput sinó el **senyal d'aprenentatge**. El cas més clar és PPO-SB3: és l'agent més escalable i ràpid, però el que menys aprofita una partida llarga amb recompensa diferida. La hipòtesi que en sorgeix és que factoritzar la partida en unitats més curtes i denses (mans) hauria de donar un senyal molt més ric. Això motiva la Fase 2.

Nota sobre l'observació. Les Fases 1 i 2 van utilitzar una versió primerenca del vector de context de 23 dimensions (239 dimensions en total). A partir de la Fase 3 es va ampliar a 24 dimensions (240 en total), tal com es descriu al capítol 4. El canvi no afecta les conclusions comparatives, atès que totes les sèries d'una mateixa fase comparteixen la mateixa observació.

5.2.2 Fase 2: *curriculum learning* (mà → partida)

Hipòtesi. Entrenar directament sobre partides senceres obliga l'agent a resoldre alhora dos problemes acoblats: jugar bé cada mà (tàctica local) i gestionar el marcador al llarg de la partida (estratègia global). El *curriculum learning* [14], que presenta primer els exemples simples i després els complexos, permet desacoblar-los. Al Truc, una *mà* és la unitat natural simple: episodi curt (~15 passos) i recompensa calculable al final. La hipòtesi és que entrenar primer sobre mans (amb l'entorn TrucEnvMa descrit al capítol 4) i després fer *finetune* sobre partides senceres accelera i millora l'aprenentatge respecte a entrenar-hi directament.

Disseny. *El curriculum de dues etapes.* S'ha dissenyat un curriculum que va de la tasca densa i curta a l'escassa i llarga (figura 5.2):

1. **Etapa de mans** (12M passos): l'agent s'entrena a TrucEnvMa, on cada mà és un episodi independent (~15 passos) amb recompensa densa normalitzada (punts/24). Aquí aprèn la tàctica local: quan jugar fort, quan acceptar un envit, quan plantar el truc.
2. **Etapa de partides** (12M passos): els pesos apresos es transfereixen a TrucEnv, on l'episodi és una partida sencera fins a 24 punts. L'agent parteix d'una política ja formada i el *finetune* recau sobre l'estratègia a llarg termini, com la gestió del marcador.




Figura 5.2: Currículum de dues etapes: mans individuals amb recompensa densa, seguides de partides senceres amb transferència dels pesos apresos (θ).

Comparació experimental. Per a cada algorisme s'executen dues configuracions amb el mateix pressupost total de 24 milions de passos: **control** (24M directament sobre partides) i **curriculum** (les dues etapes anteriors). Per aïllar l'efecte del curriculum s'elimina el *self-play* i tots els agents s'entrenen amb la mateixa distribució d'oponents (10% Random + 90% Regles). L'avaluació es fa sempre sobre partides senceres, encara que l'agent estigui aprenent sobre mans, perquè és on es vol mesurar la competència real.

Transferència al finetune. El pas de l'etapa de mans a la de partides no és automàtic: els pesos de la primera etapa (`best_mans`) es carreguen explícitament abans de la segona, via `PP0.load()` o carregant l'estat de la xarxa Q segons l'agent. A més, per al

DQN-SB3 es redueix l'exploració inicial del *finetune* ($\epsilon = 0,10$ en lloc d'1,0) i s'escurça el *warmup*, perquè la política ja està formada i no cal tornar a explorar des de zero.

Riscos. El principal és l'**oblit catastròfic**: els algorismes on-policy com PPO descarten les dades antigues a cada actualització, de manera que l'agent podria oblidar el que va aprendre sobre mans en exposar-se a les partides. Un segon risc és el desajust de distribució, ja que la distribució de mans amb el marcador a 0–0 difereix de la que apareix amb el marcador avançat.

Resultats. L'anàlisi separa les dues etapes i, per no confondre un pic transitori amb el rendiment assolit, reporta el **valor final** de cada entrenament (en acabar el pressupost), no el màxim.

Etapa 1 (mans): un salt per als agents SB3. A igualtat de pressupost (12M passos, taula 5.6), entrenar sobre mans dispara els dos agents SB3 respecte a entrenar directament sobre partides: DQN-SB3 passa del 37,2% al 68,0% i PPO-SB3, l'agent més feble de la Fase 1, del 3,8% al 84,8% (+81 pp). En canvi, per als agents de RLCard l'efecte és marginal (DQN-RLCard +2,3 pp) o fins i tot advers (NFSP-RLCard –3,0 pp): el sostre estructural de RLCard ja observat a la Fase 1 no el trenca el canvi d'entorn. L'entorn per mans aporta, doncs, un senyal d'aprenentatge molt més ric, però només els agents amb prou capacitat (els SB3) el saben aprofitar.

Etapa 2 (finetune sobre partides): el segon entrenament degrada. En transferir els pesos de mans a partides senceres, el rendiment **cau** en tots els agents (taula 5.7 i figures 5.3 i 5.4). El màxim de l'etapa 2 s'assoleix sempre al *principi*—PPO-SB3 marca el seu (75,0%) al primer punt d'avaluació (0,5M passos de finetune) i DQN-SB3 el seu (56,0%) a 1M—i després el finetune l'erosiona fins al 7,8% (PPO-SB3) i al 41,5% (DQN-SB3). Aquest màxim inicial és, de fet, el model heretat de l'etapa de mans; el finetune sobre partides no hi afegeix res i el desfà. En acabar, els dos SB3 queden per sota del seu propi control (41,5% vs 54,0%; 7,8% vs 11,5%): el segon entrenament, tal com està plantejat, és perjudicial.

Agent	Control 12M	Mans 12M	Δ
DQN-RLCard	15,2%	17,5%	+2,3
NFSP-RLCard	21,8%	18,8%	–3,0
DQN-SB3	37,2%	68,0%	+30,8
PPO-SB3	3,8%	84,8%	+81,0

Taula 5.6: Win-rate ponderat (metric) a 12M passos (mateix pressupost, avaluació sobre partides, valors finals). Entrenar sobre mans dispara els agents SB3, però amb prou feines mou els de RLCard.

5.2. Bloc 1: línia base i *curriculum learning*

Agent	Control 24M	Mans (fi etapa 1)	Partides (fi etapa 2)
DQN-RLCard	15,2%	17,5%	15,0%
NFSP-RLCard	22,2%	18,8%	19,8%
DQN-SB3	54,0%	68,0%	41,5%
PPO-SB3	11,5%	84,8%	7,8%

Taula 5.7: Win-rate ponderat (metric), valors finals (fi de pressupost). La columna «Mans» és el model en acabar l'etapa 1; «Partides», el model en acabar el *finetune* de l'etapa 2. El *finetune* sobre partides degrada el model fins per sota del control en els SB3: el millor model disponible és el de l'etapa de mans.




Figura 5.3: Corbes del *curriculum* per als agents RLCARD (win-rate ponderat). La línia ratllada és l'etapa de mans (pre-entrenament); la sòlida, el *finetune* sobre partides; la puntejada marca la transició (12M passos). Els punts són avaluacions periòdiques. Cap dels dos agents trenca el sostre estructural de RLCARD: NFSP-RLCARD fa un pic breu a la transició i torna a caure.




Figura 5.4: Corbes del *curriculum* per als agents SB3 (win-rate ponderat). Tots dos assolixen un rendiment alt en l'etapa de mans (DQN-SB3 fins al 68%, PPO-SB3 fins al 85%), però el *finetune* sobre partides el degrada: el màxim de l'etapa de partides es dona al primer punt (herència de mans) i després cau (PPO-SB3 fins al 7,8%).

El cas de **PPO-SB3** il·lustra el patró: assolix el 84,8% sobre mans però, en passar a

partides, el *finetune* el desploma fins al 7,8%. Es confirma així el risc anticipat d'**oblit catastròfic**: en ser *on-policy*, PPO descarta ràpidament la base apresada a les mans quan la distribució de partides senceres domina l'entrenament. El mateix efecte, més suau, apareix a DQN-SB3 (68,0% → 41,5%).

Decisió. La Fase 2 deixa dues conclusions. Primera: l'entrenament sobre mans (etapa 1) és la tècnica que trenca el sostre de la Fase 1, però només per als agents amb capacitat suficient, els SB3, que arriben al 84,8% (PPO-SB3) i al 68,0% (DQN-SB3) de win-rate ponderat. Aquests models de mans són el veritable lliurable del bloc. Segona: el *finetune* sobre partides senceres, tal com està plantejat, no transfereix aquest aprenentatge i fins i tot el degrada; el coll d'ampolla ja no és l'aprenentatge inicial sinó el **segon entrenament**. Millorar-lo, perquè la competència tàctica adquirida a les mans es conservi i s'estengui a la gestió de la partida sencera, és precisament l'agenda del Bloc 2.

5.2.3 Checkpoint 1: models seleccionats

Tancades les Fases 1 i 2, cal decidir quins dels quatre models continuen a la resta del treball. El criteri combina el rendiment (metric) i el cost d'entrenament, i el resultat és clar: avancen els dos agents SB3 i es descarten els dos de RLCard.

PPO-SB3 és el gran beneficiari de l'etapa de mans i passa a ser el **model de referència** del treball. De ser l'agent més feble de la Fase 1, amb l'entorn per mans arriba al 84,8% de win-rate ponderat, el guany més gran del bloc, i amb aproximadament la meitat del cost de DQN-SB3 (~40 min davant de ~5,5 h per execució). La seva narrativa resumeix la lliçó del bloc: PPO no tenia un problema de capacitat sinó de senyal d'aprenentatge, i l'entorn per mans el resol. La seva velocitat d'entrenament excel·lent permet, a més, iterar ràpidament a les fases següents. **DQN-SB3** es manté com a **referència robusta**: és el millor sobre partides senceres sense curriculum (54,0% de control a 24M), assoleix un 68,0% sobre mans i representa la família dels algorismes basats en la funció de valor, el contrapunt natural a PPO; el seu cost (~5,5 h per execució) és assumible per als experiments llargs de les fases següents.

Es descarten, en canvi, els dos agents de RLCard. **DQN-RLCard** no trenca el sostre estructural de RLCard (es queda entorn del 15–17% de metric final tant en control com amb curriculum) i és consistentment inferior a DQN-SB3 en tots els experiments. **NFSP-RLCard** és l'algorisme més lent (~17 h per execució), té un rendiment final baix (el pic transitori del 60% a la transició no es manté) i no mostra cap escalabilitat amb més còmput: el benefici és massa modest per al cost.

5.3 Bloc 2: representació de l'estat i memòria

Amb els dos agents SB3 seleccionats al Checkpoint 1, el segon bloc explora dues direccions ortogonals per superar el sostre de rendiment: millorar la *representació* de l'estat (Fase 3, dividida en arquitectura i inicialització del cos) i dotar l'agent de *memòria* entre mans (Fase 4). El Checkpoint 2 tanca el bloc fixant el model que s'adopta per a desplegament.

5.3.1 Fase 3: el feature extractor COS

La Fase 3 estudia *CosMultiInput*, un *feature extractor* convolucional propi, com a alternativa a l'extractor pla per defecte de SB3. L'estudi respon dues preguntes aco- blades: si l'**arquitectura** convolucional aporta valor per si sola (Q1, secció 5.3.1.1) i si **inicialitzar-la** amb coneixement previ del joc desbloqueja un rendiment superior (Q2, secció 5.3.1.2).

5.3.1.1 Arquitectura: CNN vs MLP

Hipòtesi. El vector pla de 240 dimensions amaga l'estructura espacial del tensor de cartes. Un MLP pla ha de *redescobrir* per ell mateix que el 4 de Copes i el 4 d'Ors comparteixen rang, o que cartes de pals diferents poden tenir forces relacionades. La hipòtesi (Q1) és que un extractor que respecta l'estructura $6 \times 4 \times 9$ del tensor de cartes (mitjançant convolucions) supera el MLP estàndard.

Disseny. *L'extractor CosMultiInput.* Per provar la hipòtesi es dissenya *CosMultiInput*, un extractor de dues branques (figura 5.5). La branca Convolutional Neural Network (CNN) aplica dues convolucions sobre el tensor (6,4,9) (taula 4.1): la primera amb nucli 1×3 detecta patrons entre rangs consecutius; la segona amb nucli 3×3 integra la informació entre pals i rangs, produint 320 dimensions. La branca densa projecta el vector de context de 24 dimensions (taula 4.2) a 32. Les dues sortides es concatenen i es projecten a 256 dimensions. La sortida coincideix amb l'amplada de la prime- ra capa oculta de la política (`net_arch=[256,256]`), de manera que *CosMultiInput* substitueix l'extractor per defecte de SB3 (*CombinedExtractor*, que simplement aplatina l'observació) sense cap altre canvi. L'adaptador *CosMultiInputSB3* (`RL/models/sb3/sb3_features_extractor.py`) fa de pont entre el vector pla i les dues branques.




Figura 5.5: *CosMultiInput*: arquitectura de dues branques. La branca CNN processa el tensor de cartes (6,4,9); la branca lineal el vector de context (24,). Les sortides es concatenen i es projecten a un vector latent de 256 dimensions.

Els tres protocols. La comparació es fa sobre els tres protocols d'entrenament introduïts a la Fase 2 (secció 5.2.2), que es recorden aquí perquè ara es comparen tots tres:

- **Control:** entrenar directament sobre *partides senceres*; la condició de referència, sense cap facilitació.
- **Curriculum:** entrenar primer sobre *mans* i després fer *finetune* sobre partides senceres (el currículum de dues etapes de la Fase 2).

- **Mans:** entrenar *exclusivament* sobre mans individuals, sense el pas posterior a partides.

Comparació experimental. Per a cada protocol i agent es compara la variant COS (amb pesos aleatoris) amb la variant MLP, amb 24 milions de passos cada combinació i la mateixa distribució d'oponents que la Fase 2 (10% Random + 90% Regles). Això suposa sis entrenaments nous amb COS i dos amb MLP sobre mans; les quatre sèries MLP de control i curriculum es reutilitzen de la Fase 2 per no reentrenar-les.

Resultats. El COS amb pesos aleatoris no supera sistemàticament el MLP (taula 5.8). Només aporta una millora clara al protocol de control per a DQN-SB3 (+10,5 punts). El protocol **mans** torna a ser el millor en termes absoluts (totes les combinacions superen el 82%), però la diferència entre COS i MLP hi és marginal (< 4 punts). La inducció estructural per si sola, amb pesos aleatoris, no és suficient per desbloquejar un avantatge. La lectura és coherent: al protocol de control, sense cap facilitació, la capacitat addicional de la CNN per extreure patrons de l'estructura de les cartes es tradueix en un guany real; al protocol de mans, el currículum d'entrenament sobre mans individuals ja exposa l'agent als patrons carta-a-carta en un context simplificat, de manera que el MLP arriba al protocol de mans amb una representació prou rica i la CNN no hi aporta res addicional.

Protocol	Agent	COS	MLP	Δ
Control	DQN-SB3	71,0%	60,5%	+10,5
Control	PPO-SB3	32,5%	35,0%	-2,5
Curriculum	DQN-SB3	56,2%	56,0%	+0,2
Curriculum	PPO-SB3	63,0%	75,0%	-12,0
Mans	DQN-SB3	82,2%	85,8%	-3,6
Mans	PPO-SB3	89,0%	87,2%	+1,8

Taula 5.8: Pic de metric (24M passos) per a COS amb pesos aleatoris vs MLP.




Figura 5.6: Pic de metric (24M passos) per protocol i agent, COS amb pesos aleatoris vs MLP. La línia discontinua marca el 80%. El COS només supera clarament el MLP al control de DQN-SB3; al protocol de mans (el millor en absolut) la diferència és marginal.

Decisió. Es fixa el protocol de mans per a la resta del bloc. Com que el COS amb pesos aleatoris no arrenca amb cap avantatge representacional, la pregunta natural és si *inicialitzar-lo* amb coneixement previ del joc canvia el resultat. Això motiva la subsubsecció següent.

5.3.1.2 Inicialització supervisada del COS

Hipòtesi. Un cos preentrenat que ja distingeix rang, pal i força de les cartes des del primer pas d'AR permet a la política concentrar-se en la presa de decisions en lloc de reaprendre la representació. La pregunta (Q2) és doble: aporta valor el preentrenament supervisat, i quin règim (congelat o ajustat) és preferible?

Disseny. *El preentrenament supervisat.* La idea és donar al cos *CosMultiInput* una representació útil de les cartes *abans* que comenci l'AR, per tal que l'agent no hagi de descobrir l'estructura del joc i la política al mateix temps. Per aconseguir-ho, s'afegeix temporalment al cos el model *ModelPreEntrenament*, que hi acobla tres caps de predicció (taula 5.9): la força de cada carta de la mà, la màscara d'accions legals i la puntuació d'envit (figura 5.7).




Figura 5.7: Esquema del preentrenament supervisat: els tres caps propaguen gradient al cos i l'obliguen a aprendre representacions sensibles a l'estructura del joc. Un cop acabat, els caps es descarten i es conserven només els pesos del cos.

El dataset es genera jugant partides amb una política pseudo-aleatòria sobre l'entorn real: a cada pas es registra l'observació de l'agent i s'extreuen automàticament les etiquetes del propi motor de joc (la força de cada carta via TrucJudger, la màscara d'accions legals de l'estat actual i els punts d'envit de la mà inicial). El resultat són 200 000 transicions amb un repartiment 80/20 entre entrenament i validació; la pèrdua combinada pondera els tres objectius ($1,0 \cdot \mathcal{L}_{\text{envit}} + 2,0 \cdot \mathcal{L}_{\text{accions}} + 2,5 \cdot \mathcal{L}_{\text{forces}}$), donant més pes als objectius que exigeixen una comprensió més fina de l'estructura de les cartes. Un cop acabat l'entrenament supervisat, els caps es descarten; la seva única funció era proporcionar gradient informatiu al cos, i el que es conserva és el coneixement que el cos ha consolidat als seus pesos.

Cap	Sortida	Mida	Pèrdua
cap_envido	Punts d'envit de la mà	1	MSE
cap_accions_legals	Màscara d'accions legals	19	BCE
cap_forces	Força de cada carta a la mà	3	MSE

Taula 5.9: Caps de predicció del *ModelPreEntrenament* per al preentrenament supervisat del cos *CosMultiInput*.

Els quatre règims. El coneixement preentrenat es pot aprofitar de maneres diferents, que constitueixen la variable d'estudi de la fase:

- **Sense COS (MLP):** l'extractor pla per defecte de SB3, sense cap inducció estructural; estableix el sostre d'un model sense coneixement de l'estructura de les cartes.
- **Scratch** (des de zero): el COS amb *pesos aleatoris*; la CNN ha d'aprendre la representació de les cartes alhora que la política.
- **Frozen** (congelat): el COS amb *pesos preentrenats supervisadament i congelats*; la representació és fixa i estable, i només s'entrena la política.
- **Finetune** (ajust fi): el COS amb pesos preentrenats que *es continuen ajustant* durant l'AR; té millor potencial però arrisca a oblidar la representació inicial.

Cada comparació aïlla un efecte: *scratch* contra MLP mesura l'efecte de l'arquitectura, i *frozen/finetune* contra *scratch* mesuren l'efecte del preentrenament.

Resultats. El règim **frozen és el millor** (taula 5.10). Per a DQN-SB3 assoleix el 91,2% (+5,4 punts sobre el MLP, +9 sobre *scratch*): el cos preentrenat i congelat actua com a extractor estable que permet a la xarxa de valor aprendre sense interferències. El *finetune* degrada respecte al *frozen* en tots dos agents: el gradient de l'AR deteriora parcialment la representació preentrenada. Per a PPO-SB3 els quatre règims convergeixen entre 87–89%, de manera que el preentrenament hi aporta poc.

Règim	DQN-SB3	PPO-SB3
Sense COS (MLP)	85,8%	87,2%
Scratch	82,2%	89,0%
Frozen	91,2%	89,5%
Finetune	88,5%	88,0%

Taula 5.10: Pic de metric (protocol mans, 24M passos) per als quatre règims d'inicialització del cos.

Decisió. El preentrenament supervisat aporta valor real, però només quan el cos queda **congelat**. S'adopta el COS preentrenat i congelat com a *backbone* estable per a la fase següent.

5.3.2 Fase 4: memòria d'oponent (LSTM) i pool d'oponents

Hipòtesi (Q3). Totes les fases anteriors entrenen contra un oponent fix i amb un agent sense estat intern. La Fase 4 introdueix dues variables: una memòria seqüencial Long Short-Term Memory (LSTM) que manté estat entre mans, i un *pool* de sis variants d'oponent (taula 5.1). Se'n deriven tres hipòtesis concretes:

- **H1:** L'LSTM millora el rendiment global respecte a un agent sense memòria entrenat amb les mateixes condicions.
- **H2:** L'agent amb LSTM mostra adaptació progressiva dins la sessió: el win-rate creix de la mà 1 a la mà 5 a mesura que l'agent infereix el patró de l'oponent.
- **H3:** El pool de sis variants no perjudica significativament la convergència d'un agent sense memòria (F4-ablació comparable a les línies base de la Fase 3.5).

Disseny. *El pool d'oponents.* En lloc d'un oponent fix, l'agent s'entrena contra sis variants de l'agent basat en regles amb estils contrastats (taula 5.1). La diversitat és deliberada: amb un únic oponent existiria una política mitjana òptima que un agent sense memòria podria memoritzar; amb sis estils clarament diferents no n'hi ha cap, de manera que l'única manera de jugar bé contra tots és *detectar* qui es té al davant i adaptar-s'hi.

Sessions multi-mà. Per donar marge a aquesta adaptació, l'episodi d'AR deixa de ser una mà i passa a ser una *sessió* de $N = 5$ mans consecutives contra el mateix oponent. El

nou entorn *TrucGymEnvSessio* envolta *TrucGymEnvMa* i *intercepta* els senyals de final (terminated) intermedis, de manera que l'estat de l'LSTM no es reinicia fins al final de les cinc mans; al començament de cada sessió es mostreja un oponent nou del pool.

L'arquitectura amb memòria. La cadena de processament és obs(240) → COS congelat(256) → LSTM(256) → MLP lleuger → caps de política i valor. S'usa *RecurrentPPO* (de *sb3-contrib*) amb *retropropagació en el temps truncada* (secció 2.3.3) sobre seqüències, on el *batch_size* es mesura en seqüències i no en transicions individuals. No s'usa DRQN (l'anàleg basat en la funció de valor) perquè requeriria un *replay buffer* seqüencial no disponible a SB3.

Pressupost i avaluació. Es comparen dos entrenaments nous amb les línies base de la Fase 3.5: **F4-ablació** (PPO + COS congelat + pool, sense memòria) i **F4-complet** (*RecurrentPPO* amb LSTM sobre el COS congelat + pool); la primera comparació aïlla l'efecte del pool i la segona, l'efecte de la memòria. Cada entrenament nou s'entrena 12M passos, la meitat que a la Fase 3.5, perquè la retropropagació en el temps encareix molt el còmput. L'avaluació, a més del win-rate ponderat (metric) habitual, acumula el win-rate *per posició dins la sessió* (de la mà 1 a la 5) per detectar si l'agent millora a mesura que coneix l'oponent.

Resultats. Cap de les tres hipòtesis es valida plenament (taula 5.11). Les figures 5.8 i 5.9 mostren l'evolució i els pics del win-rate ponderat (metric); la figura 5.10 detalla el win-rate per posició dins la sessió, clau per a H2.




Figura 5.8: Evolució del win-rate ponderat (metric) al llarg de l'entrenament per als quatre entrenaments de la Fase 4, tallats a 12M passos. Línies discontinúes: línies base de la Fase 3.5 (sense pool); línies sòlides: entrenaments amb pool; gruix addicional: model amb LSTM. La línia puntejada gris marca el 85%.

5.3. Bloc 2: representació de l'estat i memòria




Figura 5.9: Pic de metric per a cada run, tots tallats al pressupost comú de 12M passos. DQN frozen assolix 87,8% dins el pressupost; el seu pic global és 91,2% a 23M passos.




Figura 5.10: Win-rate per posició dins la sessió (mà 1 a mà 5) per als dos runs de la Fase 4 (mitjana de les cinc darreres avaluacions). El Δ indica la diferència entre la mà 5 i la mà 1. La línia puntejada marca el 50%.

Run	Memòria	Pic metric (12M)	Temps
DQN frozen (F3.5)	No	87,8%	—
PPO frozen (F3.5)	No	89,5%	0,33 h
F4-ablació	No	86,0%	0,33 h
F4-complet	LSTM 256	82,0%	15,2 h

Taula 5.11: Resultats de la Fase 4 (pressupost igualat a 12M passos). DQN frozen mostra el seu màxim dins el pressupost de 12M; el seu pic global és del 91,2% a 23M.

H1: l'LSTM millora el rendiment global. No es valida. F4-complet assoleix un 82,0% de metric, 4 punts per sota de F4-ablació (86,0%), que entrena amb el mateix pool però sense memòria. A igual pressupost (12M passos), la memòria no aporta cap guany global i a més eleva el cost computacional 46× (15,2 h vs 0,33 h).

H2: adaptació progressiva dins la sessió. No es valida. La corba de win-rate per posició (mà 1 a mà 5, figura 5.10) és sorollosa i no monòtona: [77,5; 73,2; 80,7; 71,1; 78,9], $\Delta = +1,4$ punts. El patró no és gaire diferent del de F4-ablació (sense memòria), la qual cosa descarta l'aprenentatge adaptatiu i apunta a un artefacte de la mida de mostra (~56 sessions per posició), insuficient per detectar tendències fiables.

H3: el pool no perjudica significativament la convergència. Parcialment valida. F4-ablació (86,0%) queda 3,5 punts sota PPO frozen (89,5%), just al límit del criteri ± 3 punts. El pool dificulta lleugerament la convergència sense memòria, però el delta és prou petit per no descartar la configuració.

La causa subjacent del fracàs de H1 i H2 podria ser el **desajust entre entrenament i avaluació**: s'entrena sobre sessions de 5 mans (~50 passos), però s'avalua sobre sessions de 5 partides senceres (~500 passos), un context deu vegades més llarg que la xarxa no ha vist mai. S'hi sumen el pressupost reduït (12M vs 24M de les línies base) i les sessions d'entrenament massa curtes perquè la retropropagació en el temps propagui senyals d'adaptació significatius.

Decisió. Els resultats revelen marges de millora concrets. El canvi més crític seria **alin·near el context d'entrenament i d'avaluació**: substituir les sessions de 5 mans (~50 passos) per sessions de partides senceres (~500 passos), de manera que la xarxa hagi vist durant l'entrenament el mateix horitzó temporal que a l'avaluació. Un **LSTM més petit** (64–128 unitats en lloc de 256) reduiria el cost computacional i facilitaria la convergència; augmentar el **pressupost** fins als 24M passos de les línies base i allargar les **seqüències de BPTT** donarien a la memòria el temps i el context necessaris per propagar senyals d'adaptació reals.

Malgrat aquestes millores possibles, aquest TFG descarta la línia de recerca recurrent: amb H1 i H2 invalidades, H3 just al límit i un cost computacional 46× superior, la relació cost-benefici no justifica continuar-la dins del pressupost disponible. La tria entre els candidats restants (F4-ablació i les línies base de la Fase 3.5) es resol al Checkpoint 2.

5.3.3 Checkpoint 2: model seleccionat

Tancades les Fases 3 i 4, el model que s'adopta per a desplegament és **F4-ablació** (PPO + COS congelat + pool, 86,0% a 12M passos). La decisió pondera rendiment, robustesa i cost.

La raó principal és la **robustesa davant estils diversos**. F4-ablació s'ha entrenat contra les sis variants de l'agent basat en regles, de manera que la seva política és generalista; les millors línies base de la Fase 3.5 (DQN i PPO frozen) van entrenar sempre contra un oponent fix i no s'han enfrontat a aquesta diversitat. En un context de desplegament real, on l'oponent és desconegut, aquesta generalitat és més valuosa que uns quants punts de win-rate aconseguits contra un únic adversari. A això s'hi suma la **rapidesa d'entrenament** (0,33 h per execució, davant les 15,2 h de F4-complet o les diverses hores del DQN), que permet iterar i reentrenar amb facilitat, i un **rendiment competitiu** al pressupost igualat (només 3,5 punts sota PPO frozen).

DQN frozen té el millor win-rate brut (91,2% al pic global), però va ser entrenat contra un oponent fix i no s'ha provat contra el pool; per això no es tria. Finalment, l'LSTM (F4-complet) queda descartada: un cost 46× superior i un rendiment 4 punts inferior no compensen, i cap de les seves hipòtesis s'ha validat.

Aquesta robustesa, però, encara no s'ha quantificat: la metric clàssica promitja entre oponents i pot amagar debilitats davant estils concrets. Mesurar-la i millorar-la és l'objectiu del Bloc 3.

5.4 Bloc 3: robustesa i aproximació a l'equilibri

El model seleccionat al Checkpoint 2 (F4-ablació: PPO + COS congelat + pool) mostra un defecte estructural: ha convergit a una política quasi-determinista especialitzada en explotar els patrons fixos de les sis variants de l'agent basat en regles. Contra un oponent que varia l'estil, aquesta especialització es converteix en una debilitat. A més, la metric clàssica (win-rate ponderat) no detecta el problema, perquè promitja el rendiment entre variants i amaga la variança. El tercer bloc ataca el problema des de dues bandes: la Fase 5 introdueix mètriques d'explotabilitat i un *self-play* mixt inspirat en el Fictitious Self-Play (FSP) per reduir la predictibilitat; la Fase 6 afegeix el component de política mitjana del NFSP complet per acostar el sistema a l'equilibri.

5.4.1 Fase 5: *self-play* mixt i robustesa

Hipòtesi. Un agent entrenat exclusivament contra oponents fixos és explotable: qual-sevol oponent que surti d'aquests patrons pot descobrir-ne les debilitats. La pregunta de recerca (Q4) és: pot un *pool* d'entrenament que combini les variants de l'agent basat en regles amb *snapshots* del propi agent (FSP simplificat) reduir l'explotabilitat sense degradar el rendiment global? Les hipòtesis concretes són:

- **H1:** el self-play no degrada la metric clàssica respecte a la línia base extesa (F4-ablació-48M): $\text{metric}_{F5} \geq \text{metric}_{F4} - 3 \text{ pp}$. El marge de 3 pp es fixa a l'ordre de magnitud del soroll estadístic esperable de l'avaluació: amb 100 partides per oponent (secció 5.1), l'error estàndard d'un win-rate individual proper al 50% és d'uns 5 pp, que en combinar-se a la mètrica ponderada (equació 5.1) es redueix a

uns 4 pp; diferències per sota d'aquest marge no es poden distingir amb fiabilitat del soroll de mostreig.

- **H2:** la robustesa inter-estil (*metric_robust*) millora respecte a F4-ablació.
- **H3:** l'auto-explotabilitat final queda per sota de 10 punts percentuals.

Disseny. *El problema de l'explotabilitat.* La metric clàssica amaga la variança de rendiment entre estils d'oponent. Un agent pot obtenir un 95% contra una variant conservadora i un 60% contra una farolera, i mostrar igualment una mètrica aparentment bona. Per quantificar la robustesa s'introdueixen dues mètriques complementàries. La **robustesa inter-estil** penalitza la dispersió:

$$\text{metric_robust} = \overline{\text{wr}}_{\text{pool}} - 0,5 \cdot \text{std}(\text{wr}_{\text{variant}}), \quad (5.2)$$

on $\overline{\text{wr}}_{\text{pool}}$ és el win-rate mitjà contra les sis variants i std la seva desviació típica. Un agent que guanya igual contra tots té $\text{std} = 0$ i, per tant, $\text{metric_robust} = \overline{\text{wr}}_{\text{pool}}$; un agent especialitzat paga una penalització proporcional a la irregularitat. L'**auto-explotabilitat** mesura la distància a l'equilibri:

$$\text{auto-explotabilitat} = |\text{wr}_{\text{vs_recents}} - 50|, \quad (5.3)$$

on $\text{wr}_{\text{vs_recents}}$ és el win-rate del model actual contra els tres *snapshots* propis més recents. A prop del Nash cap versió pot explotar sistemàticament una altra i el valor tendeix a 0.

FSP simplifcat. El Fictitious Play [13] és un procediment iteratiu on cada jugador tria la millor resposta a la política *promig* de l'oponent en totes les iteracions anteriors; Brown va demostrar la convergència a Nash en jocs finits de suma zero. El NFSP (capítol 2) adapta aquest principi a xarxes neuronals. La variant d'aquesta fase, *Simplified FSP*, elimina el component supervisat (que es reserva per a la Fase 6) i aproxima la política promig de l'oponent mantenint una finestra rodant de *snapshots* del propi agent. Mostrejant oponents del pool d'*snapshots*, el PPO s'enfronta a una distribució d'estratègies que representa la seva pròpia evolució i no es pot especialitzar en un únic patró.

El pool mixt. El pool combina les sis variants de l'agent basat en regles (sempre presents, per garantir diversitat des del primer pas i comparabilitat amb F4) amb una finestra rodant de fins a sis *snapshots* del propi agent (un cada milió de passos). El mostreig és uniform entre tots els candidats: la proporció de self-play augmenta de 0/6 al pas 0 fins a 6/12 (50%) quan el pool és ple, de manera gradual i sense fer obsolets els oponents de regles (figura 5.11).

5.4. Bloc 3: robustesa i aproximació a l'equilibri




Figura 5.11: Composició del pool mixt al llarg del temps. Esquerra: cada fila és un instant clau; les caselles blaves (R1–R6) són les sis variants de l'agent basat en regles, sempre presents; les caselles vermelles (S1–S6) són els *snapshots* del propi agent, afegits un a un cada milió de passos. Dreta: evolució de la proporció de self-play, que passa de 0% al pas 0 fins al 50% quan el pool és ple (pas 6M en endavant).

Comparació experimental. Es comparen dos runs de 48M passos amb el mateix pressupost: **F4-ablació-48M** (PPO + COS congelat, pool fix de sis l'agent basat en regles, sense self-play, línia base estesa) i **F5-selfplay** (pool mixt, warm-start des del model seleccionat de F4-ablació-48M). Les arquitectures i els hiperparàmetres PPO són idèntics; l'única variable és la composició del pool.

Resultats. El self-play trenca el compromís entre rendiment i robustesa: F5 manté la mètrica clàssica i alhora millora molt la robustesa. Les tres hipòtesis es validen (taula 5.12).




Figura 5.12: Evolució de la metric (esquerra) i la metric_robust (dreta) al llarg de 48M passos. Línia discontinua: F4-ablació-48M (sense self-play); línia sòlida: F5-selfplay. La metric és pràcticament idèntica (H1), però la metric_robust de F5 creix de forma sostenuda i supera àmpliament la de F4 (H2).

5. METODOLOGIA D'ENTRENAMENT




Figura 5.13: Win-rate per variant d'oponent (models seleccionats). F4 (blau) mostra una distribució irregular: alt contra l'estil conservador i equilibrat, baix contra l'agressiu i el faroler. F5 (vermell) reequilibra la distribució: puja tots els valors baixos al 80–85% al preu d'abaixar l'estil conservador (la variació inversa és el senyal que la política ja no s'especialitza).

Run	Pic metric	Step	Pic metric_robust	Auto-explot.
F4-ablació-48M	89,0%	24M	73,2%	—
F5-selfplay	89,2%	41,5M	77,8%	4,7 pp

Taula 5.12: Resum de la Fase 5 (pressupost de 48M passos). F5 iguala la metric clàssica i supera la robustesa en 4,6 punts.

Variant	F4-ablació	F5-selfplay	Δ
Conservador	75,0%	55,0%	−20,0
Agressiu	55,0%	80,0%	+25,0
Truc-bot	55,0%	85,0%	+30,0
Envit-bot	80,0%	85,0%	+5,0
Faroler	50,0%	80,0%	+30,0
Equilibrat	80,0%	90,0%	+10,0
$\overline{wr}_{pool}$	65,8%	79,2%	+13,4
std_{pool}	12,7%	11,3%	−1,4
metric_robust	59,5%	73,5%	+14,0

Taula 5.13: Win-rate per variant del pool: F4-ablació vs F5-selfplay (models seleccionats). El self-play apuja tots els valors baixos i redueix la dispersió; el descens contra l'estil conservador és el reequilibri esperat.

H1 — metric sense degradació. Valida. F5 assoleix 89,2% (figura 5.12, esquerra), pràcticament idèntic al 89,0% de F4, molt per sobre del llindar de 86,0%.

H2 — millora de la robustesa. Valida. El pic de *metric_robust* puja de 73,2% a 77,8% (+4,6 pp), i el *metric_robust* del model de F5 (73,5%) supera el del model de F4 (59,5%) en 14,0 punts. La figura 5.13 mostra el reequilibri: F4 tenia win-rates de 50–55% contra els estils agressiu i faroler; F5 els puja al 80–85%.

H3 — auto-explotabilitat. Valida. L'auto-explotabilitat final = 4,7 pp, molt per sota del llindar de 10 pp.

Decisió. Les tres hipòtesis es validen: el self-play mixt millora la robustesa sense perjudicar el rendiment global. Tanmateix, la dispersió entre estils (std_{pool}) no baixa de manera clara (11,3% vs 12,7%): el PPO continua especialitzant-se i des-especialitzant-se sense arribar a una estratègia d'equilibri estable. La causa és que el FSP simplificat no té cap component que approximi la política *promig* de l'historial complet; sense aquesta àncora, el PPO cicla. El component que l'hi aporta és la xarxa de política mitjana del NFSP complet, que s'implementa a la Fase 6.

5.4.2 Fase 6: NFSP complet

Hipòtesi. Segons el NFSP [11], la convergència a un equilibri de Nash en jocs d'informació parcial requereix jugar des de la política *promig* de tot l'historial, no des de la millor resposta del darrer pas. La pregunta de recerca (Q5) és: pot afegir una xarxa de política mitjana apresada de forma supervisada acostar el sistema a l'equilibri sense perdre rendiment competitiu? Les hipòtesis concretes són:

- **H1:** no hi ha regressió de rendiment: $\text{metric}_{F6} \geq \text{metric}_{F5} - 3 \text{ pp}$.
- **H2:** la robustesa inter-estil es manté dins un marge petit: $\text{metric_robust}_{F6} \geq \text{metric_robust}_{F5} - 2 \text{ pp}$.
- **H3:** existeix algun *checkpoint* amb $\text{exploit_vs_sl} < 8 \text{ pp}$ i $\text{nash_valid} = 1$. El llindar de 8 pp es fixa lleugerament per sota del 10 pp de la Fase 5, i $\text{wr}_{\text{vs_sl}}$ s'avalua amb 60 partides balancejades (resolució de 1,67 pp).

Nota. Els marges de H1 i H2 no són arbitraris. El de 3 pp a H1 manté el criteri de no-regressió ja usat a les fases anteriors, compatible amb el soroll de mostreig de les avaluacions periòdiques. El de 2 pp a H2 és més estricte perquè la robustesa és l'objectiu principal del bloc: s'accepta una pèrdua petita, però no una degradació substancial de *metric_robust*.

Disseny. *La limitació del FSP simplificat.* La Fase 5 mostra que, sense cap àncora que representi la política *promig* de l'historial, el PPO oscil·la entre millors respostes i no convergeix. El NFSP complet [11] resol aquest problema afegint un segon aprenent Supervised Learning (SL) que imita contínuament l'historial de decisions del PPO i proporciona l'àncora que el FSP simplificat no té.

L'arquitectura NFSP S'implementen dos bucles d'optimització en paral·lel sobre el mateix *backbone* COS congelat. El **bucle RL** és el PPO habitual: observa l'estat, tria una acció i rep una recompensa. El **bucle SL** entrena la xarxa *AveragePolicyNet* per

imitar l'historial de decisions del PPO mitjançant cross-entropy; en paral·lel, el pool d'oponents (NFSPPool) barreja, amb probabilitat $\eta = 0,5$, la política mitjana (SL) i els agents del pool de la Fase 5 (regles + snapshots). Amb $\eta = 0,5$, la meitat de les partides d'entrenament es juguen contra l'àncora SL i l'altra meitat contra oponents variats; el PPO aprèn la millor resposta a una distribució mixta que no pot explotar simplement sobreespecialitzant-se.

El Reservoir Buffer. L'historial de decisions del PPO s'emmagatzema en una memòria uniforme de 200 000 mostres que manté cada acció amb probabilitat igual, independentment del moment en què es va prendre. Això evita biaix temporal cap al comportament recent i representa la política promig real de tot l'historial. El bucle SL s'actualitza cada 50 000 passos amb un *minibatch* d'aquesta memòria.

Les mètriques Nash. A les mètriques de la Fase 5 s'afegeixen quatre noves mètriques que capturen el comportament d'equilibri:

- **exploit_vs_sl** — el *Nash gap* empíric, definit com $|wr_{vs_sl} - 50|$, on wr_{vs_sl} és el win-rate de la millor resposta (PPO) contra la política mitjana (SL). Si aquest valor tendeix a 0, la millor resposta ja no pot explotar la política mitjana, que és la definició empírica d'equilibri de Nash.
- **calib_envit i calib_truc** — mètriques de calibració estratègica que mesuren la capacitat de la política SL de respondre correctament en situacions crítics (envit i truc). Es calculen sobre la primera decisió de cada mà, comparant la freqüència d'aposta en buckets alts (envit ≥ 29 i força ≥ 216) vs. buckets baixos.
- **calib_combined** — la mitjana de calib_envit i calib_truc, que sintetitza la qualitat estratègica global de l'SL.
- **nash_valid** — un indicador binari que marca si el punt és prou madur per considerar-se vàlid: reservoir ple, maduresa mínima en passos ($\geq 8M$) i no-degeneració (calib_envit ≥ 15 pp i $wr_{envit_bot} \geq 50\%$). Amb aquest gate, la selecció de best_nash segueix un criteri dual: només es guarda si millora simultàniament exploit_vs_sl i calib_combined.

Mecanismes d'estabilitat. Quan la calibració de la SL col·lapsa, el seu ús al pool es pausa temporalment i es reprèn quan torna a valors segurs. Això evita contaminar el bucle RL amb una política mitjana degradada. També s'aplica un early-stopping orientat a estabilitat Nash: si apareixen diverses avaluacions nash_valid consecutives sense millora dual, el run s'atura.

Comparació experimental. El run F6-NFSP parteix per warm-start de best_robust.zip de la Fase 5, manté $\eta = 0,5$, reservoir de 200 000 mostres i actualització SL cada 50 000 passos. L'entrenament arriba als 20M passos i s'atura anticipadament per l'early-stopping Nash (evals_sense_millora=8). La comparació directa és amb F5-selfplay.

Resultats. F6 manté paritat en rendiment brut, no millora la robustesa inter-estil i, al mateix temps, valida un punt Nash genuí amb criteris de maduresa i calibració (taula 5.14).

5.4. Bloc 3: robustesa i aproximació a l'equilibri




Figura 5.14: Corbes principals de F6-NFSP en tres panells: `metric`, `metric_robust` i `std_pool`, amb F5-selfplay com a referència discontinua. El warm-start accelera el pic inicial de `metric`, però la robustesa i la dispersió mostren estabilització més lenta fins a l'aturada anticipada als 20M passos.




Figura 5.15: Panell esquerre: trajectòria del *Nash gap* empíric (`exploit_vs_sl`) amb llinar de 8 pp. Panell dret: evolució de la calibració estratègica (`calib_envit`, `calib_truc` i `calib_combined`).

Mètrica	F4-ablació	F5-selfplay	F6-NFSP
metric màx	89,0%	89,2%	88,8%
metric_robust màx	73,2%	77,8%	70,2%
exploit_vs_sl mínim Nash vàlid	—	—	0,0 pp
Punts nash_valid amb exploit_vs_sl < 8 pp	—	—	15

Taula 5.14: Comparativa F4/F5/F6 amb mètriques de rendiment i criteris Nash. F6 assoleix Nash genuí però no redueix la dispersió inter-estil respecte a F5.

H1 — sense regressió. Valida. F6 arriba a 88,8% de `metric`, davant 89,2% de F5 (diferència de -0,5 pp), dins el marge de 3 pp fixat a la hipòtesi.

H2 — robustesa inter-estil. Falla. F6 obté 70,2% de `metric_robust`, per sota del 77,8% de F5 (diferència de -7,6 pp, fora del marge de 2 pp). El balanç $\eta = 0,5$ i la diversitat limitada del reservoir no redueixen prou la dispersió entre estils, fet que es reflecteix en `std_pool` = 7,9% al pic robust.

H3 — Nash gap. Valida. El run conté 23 punts amb `nash_valid` = 1, i 15 d'aquests compleixen `exploit_vs_sl` < 8 pp. El mínim Nash vàlid és 0,0 pp al pas 16M, amb reser-

voir ple, política SL madura i calibració no degenerada. Com que $w_{r_{vs_sl}}$ es calcula amb 60 partides (resolució 1,67 pp), el valor 0,0 pp correspon a un empat 30/30 i és un punt Nash genuí.

Decisió. El run de F6 conserva quatre checkpoints de la millor resposta (PPO Policy Net) i la política mitjana final:

- `best.zip` (metric màxima).
- `best_robust.zip` (metric_robust màxima).
- `best_nash.zip` (mínim exploit_vs_sl sota gate Nash vàlid).
- `best_calib.zip` (calib_combined màxima).
- `sl_final.pt` (pesos finals de la política SL).

Amb això es tanca l'arc experimental: des d'agents que no superaven el 40% a la Fase 1 fins a tres candidats a desplegament, cadascun amb un perfil diferent. La selecció definitiva del model de desplegament es resol al Checkpoint 3 (secció 5.4.3).

5.4.3 Checkpoint 3: model de desplegament

La Fase 6 produeix múltiples checkpoints al llarg de l'entrenament: `best.zip` (màxima metric), `best_robust.zip` (màxima metric_robust), `best_calib.zip` (calibració estratègica òptima), `best_nash.zip` (Nash gap mínim vàlid amb dual criterion) i `final.zip` (últim checkpoint pre-early-stopping). Els candidats s'han avaluat de forma independent i precisa amb 1000 partides balancejades per posició (meitat com a mà, meitat com a segon jugador), i cada model s'ha mesurat contra **el seu propi `sl_final.pt`**. Aquesta distinció és clau: l'`exploit_vs_sl` mesura quant pot explotar el PPO la seva pròpia política SL; és una quantificació del Nash gap respecte a l'àncora SL amb la qual ha conviscut durant l'entrenament (taula 5.15).

Model	<code>wr_pool_mean</code>	<code>metric_robust</code>	σ_{pool}	<code>exploit_vs_sl</code>
<code>best_nash</code>	67,0%	64,4%	5,1	0,7 pp
<code>best_robust</code>	66,8%	63,8%	6,0	2,5 pp
<code>best_calib</code>	64,9%	61,9%	6,0	3,4 pp
<code>best</code>	65,6%	62,7%	5,9	0,4 pp
<code>final</code>	63,8%	60,7%	6,2	2,6 pp

Taula 5.15: Candidats de desplegament de la Fase 6, avaluats amb 1000 partides balancejades contra les 6 variants del pool. Criteri primari: Nash gap `exploit_vs_sl` < 8 pp (tots passen). Desempat: `metric_robust` màxima, on destaca `best_nash` (64,4%).

Criteri de selecció. El criteri primari és el Nash gap (`exploit_vs_sl` < 8 pp); tots els cinc candidats el satisfan, confirmant que la maduresa del SL (alcançada al voltant dels 8M passos per la gate `nash_valid`) permet detectar equilibris genuïns. El desempat és la `metric_robust` màxima, que quantifica la robustesa del PPO davant de la diversitat de l'oponent:

- **best_nash**: 64,4% (líder en robustesa).
- **best_robust**: 63,8% (0,6 pp menys, però dissenyat per a robustesa a priori).
- **best**: 62,7% (2d millor en robustesa; menor exploit_vs_sl de 0,4 pp, però el criteri primari és Nash, no sobreexplotació).
- **best_calib**: 61,9% (sacrifica robustesa per calibració d'accions).
- **final**: 60,7% (degeneració per early-stopping).

El criteridual de **best_nash** (baixa exploit_vs_sl i puja calib_combined alhora) selecciona un checkpoint que simultaneja dos objectius: estabilitat Nash i qualitat estratègica. Així, **best_nash** queda triada com a **model de desplegament**.

Perfil de comportament. L'anàlisi conductual del model seleccionat (300 partides contra un agent equilibrat) revela que **best_nash** mostra taxes d'envit prudents (taxa 2–3%, similar als resultats més conservadors de la Fase 5), mentre les apostes de truc segueixen sent freqüents ($\approx 72\%$). L'anàlisi de calibració mostra que la relació entre la força de la mà i l'acció presa es manté coherent: ni sobreaposta ni subestimates. Això suggereix que la política ha après una estratègia equilibrada on l'ancorament al SL durant l'entrenament NFSP ha impedit la sobreexplotació de l'oponent i ha promogut comportaments més sostenibles. L'anàlisi detallat d'aquest comportament es presenta al capítol 6.

RESULTATS

Aquest capítol analitza el comportament del model adoptat per a desplegament (`best_nash.zip` de la Fase 6, secció 5.4.3). L'anàlisi es fa a dos nivells. Primer, una anàlisi **micro** i numèrica: es simulen milers de partides contra oponents de referència i es registra cada decisió del model amb el seu context (força de la mà, punts d'envit, ronda, marcador), per caracteritzar el seu *estil emergent*. Segon, una avaluació **qualitativa** del comportament mitjançant una rúbrica pensada per ser omplerta jugant-hi.

6.1 Anàlisi numèrica del model desplegat

Metodologia. S'han simulat 1 000 partides senceres balancejades per posició contra cada oponent: l'agent aleatori, les sis variants de l'agent basat en regles i el model contra si mateix (*self*), és a dir 8 000 partides i prop de 107 000 decisions del model. A cada torn s'han registrat l'acció triada, el context (força de la mà, punts d'envit, ronda, marcador i posició de mà o segon) i, com que el model és determinista en avaluació (tria l'acció de probabilitat màxima), també la **distribució de probabilitats** que la xarxa assigna a les accions. Això permet distingir el que el model *fa* (freqüència realitzada) del que ha *après* (probabilitat tova), un matís important perquè la seva política és molt poc entròpica. Per no confondre la freqüència d'una acció amb la seva disponibilitat, totes les propensions es condicionen a què l'acció sigui **legal** i al **context de decisió** (obrir, respondre o reapujar), tractant truc i envit per separat. Com a línia de comparació es registra també el comportament de l'agent basat en regles equilibrat.

6.1.1 Rendiment per oponent

El model bat tots els oponents del pool amb marge i, com era d'esperar, empata contra si mateix (taula 6.1, figura 6.1). Domina l'agent aleatori (88,2%) i guanya de forma consistent a totes les variants de regles (entre el 55,0% de l'agressiu i el 74,8% del conservador), amb un marge de punts ampli.

6. RESULTATS

Oponent	WR	Punts model	Punts rival
Aleatori	88,2%	28,1	5,5
Conservador	74,8%	24,3	8,9
Agressiu	55,0%	19,1	13,9
Truc-bot	62,7%	20,4	10,5
Envit-bot	71,1%	23,7	11,9
Faroler	61,5%	20,0	11,9
Equilibrat	71,1%	22,3	9,8
<i>Self</i>	49,8%	12,8	12,9

Taula 6.1: Rendiment del model desplegat per oponent (1 000 partides balancejades cadascun).




Figura 6.1: Win-rate del model desplegat contra cada oponent. Domina tots els estils del pool i empata contra si mateix.

6.1.2 Perfil d'estil emergent

El comportament estratègic del model difereix notablement del de l'agent basat en regles equilibrat (figura 6.2). El model obre el truc el 78,3% de les vegades que és legal fer-ho (davant el 15,7% de l'AR), mai es retira davant un truc cantat (0% de fora_truc, davant el 30,7% de l'AR) i reapuja el truc el 58,6% de les vegades (davant el 8,5% de l'AR). Per l'envit, obre menys que l'AR (23,7% davant el 40,4%), però accepta amb molta més freqüència: 71,0% davant el 39,5% de l'AR, indicant que quan l'oponent canta envit el model tendeix a acceptar el repte.

La política és parcialment estocàstica: l'entropia mitjana és de 0,81 nats (mediana 0,78) sobre un màxim teòric de 1,79 per a sis accions. Només el 9% de les decisions són quasi-deterministes, cosa que revela que el model manté una distribució de probabilitats repartida entre diverses accions en la majoria de situacions. L'*exploit_vs_sl* de 0,7 pp mesurat al Checkpoint 3 confirma que aquesta variabilitat és coherent amb la proximitat a l'equilibri de Nash: una política mixta és per definició menys exploitable que una de purament determinista.




Figura 6.2: Perfil d'estil emergent del model (vermell) comparat amb l'agent basat en regles equilibrat (blau), sobre cinc eixos normalitzats. El model és molt més agressiu al truc i mai no es retira, però obre envit menys que l'AR.

6.1.3 Política condicionada a la força de la mà

La relació entre força de la mà i aposta de truc és *inversa*: amb mà feble la probabilitat d'obrir truc és del 93%, mentre que amb mà forta o molt forta baixa al 29–41% depenent de la puntuació d'envit disponible (figura 6.3, esquerra). Aquesta inversió evidencia una estratègia de farol sistemàtic amb les cartes pitjors i una postura més cautelosa quan la mà és bona. La distribució inversa (figura 6.3, dreta) ho confirma: quan obre truc la força mediana de la mà és de 0,50 (igual a quan juga carta), però quan accepta truc és de 0,40, indicant que el model manté el truc independent de la força en la majoria de casos. Quan obre envit la puntuació mediana és de 29 punts; quan descarta l'envit és de 6 punts, mostrant una selecció clara basada en la qualitat de la mà per a l'envit.

6. RESULTATS




Figura 6.3: Política condicionada. A dalt: probabilitat de cada acció segons la força de la mà (esquerra) i els punts d'envit (dreta). A baix: distribució de la força de la mà i dels punts d'envit per a cada acció.

6.1.4 Comportament contextual

Per rondes dins d'una mà, l'agressió al truc *s'escalada* progressivament: el model obre truc el 40,6% dels torns de primera ronda quan juga de mà (33,4% de segon), s'incrementa fins al 85,1%/87,3% a la segona ronda, i arriba gairebé al màxim (96,9%/97,4%) a la tercera (figura 6.4, esquerra). La posició de joc és rellevant sobretot a la primera ronda; a partir de la segona el model aposta truc gairebé independentment de si va de mà o de segon. En canvi, **no adapta** la seva agressió al marcador: aposta truc entre el 49,9% i el 52,0% de mà i entre el 46,7% i el 49,5% de segon, de forma pràcticament plana tant si va per darrere, igualat o per davant (figura 6.4, dreta). Aquesta estabilitat respecte al marcador és coherent amb una estratègia propera a l'equilibri, on adaptar l'agressió al context de puntuació crearia patrons explotables.

6.2. Avaluació qualitativa del comportament




Figura 6.4: Comportament contextual. Esquerra: distribució d'accions per número de ronda dins la mà. Dreta: agressió (% d'apostes de truc i d'envit) segons la situació al marcador.

6.2 Avaluació qualitativa del comportament

L'anàlisi numèrica caracteritza *què* fa el model, però no si el seu joc resulta *creïble* per a una persona. Per avaluar-ho s'ha dissenyat una rúbrica (taula ??), pensada per ser omplerta jugant entre 10 i 20 partides senceres contra el model desplegat a través de la interfície d'escriptori. La rúbrica es fixa **abans** de jugar per evitar el biaix de racionalitzar el comportament observat, i puntua vuit criteris en una escala d'1 (molt deficient) a 5 (excel·lent).

A partir de l'anàlisi micro es pot formular una hipòtesi prèvia: la manca d'adaptació al marcador (agressió de truc quasi plana en totes les situacions) hauria de traduir-se en puntuació baixa al criteri **adaptació al marcador** (C6). L'escalada progressiva de l'agressió de truc per rondes és un patró llegible però racionalment defensable, per la qual cosa la **credibilitat del farol** (C2) podria rebre una puntuació moderada. La gestió de l'envit —obertura selectiva del 23,7% amb mans d'envit alt i acceptació del 71,0% quan l'oponent el canta— és racional i podria traduir-se en una puntuació positiva per al criteri **gestió de l'envit** (C1). L'avaluació qualitativa permetrà confirmar o refutar si aquest estil, estadísticament proper a Nash, resulta o no creïble en el joc real. Els resultats numèrics de la rúbrica es presenten un cop completada la fase de joc.

CAPÍTOL 7

CONCLUSIONS

[Conclusions del treball: resum del context i del problema, principals conclusions, implicacions teòriques i pràctiques, limitacions i treball futur.]



HIPERPARÀMETRES DELS MODELS

[Taules amb els hiperparàmetres complets de cada algorisme (DQN-RLCard, NFSP-RLCard, DQN-SB3, PPO-SB3) per a cada fase experimental.]

APÈNDIX

RESULTATS COMPLETS PER FASE

[Taules amb tots els valors numèrics dels experiments: mètriques finals, temps d'entrenament, etc.]

BIBLIOGRAFIA

- [1] J. Huizinga, *Homo Ludens: A Study of the Play-Element in Culture*. Routledge & Kegan Paul, 1938. 1
- [2] M. Campbell, A. J. Hoane Jr., and F.-h. Hsu, “Deep Blue,” *Artificial Intelligence*, vol. 134, no. 1–2, pp. 57–83, 2002. 1.1
- [3] D. Silver *et al.*, “Mastering the game of Go with deep neural networks and tree search,” *Nature*, vol. 529, pp. 484–489, 2016. 1.1
- [4] C. Berner *et al.*, “Dota 2 with large scale deep reinforcement learning,” 2019, arXiv:1912.06680. 1.1
- [5] N. Brown and T. Sandholm, “Superhuman AI for heads-up no-limit poker: Libratus beats top professionals,” *Science*, vol. 359, no. 6374, pp. 418–424, 2018. 1.2, 2.2
- [6] ———, “Superhuman AI for multiplayer poker,” *Science*, vol. 365, no. 6456, pp. 885–890, 2019. 1.2, 2.2, 2.3.4
- [7] Retruc.net, “Reglement del truc,” <https://retruc.net/reglamenttruc>, 2024, accedit: 2026. 1.3
- [8] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, 2018. 2.1
- [9] V. Mnih *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, pp. 529–533, 2015. 2.2, 2.3.1
- [10] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017. 2.2, 2.3.2
- [11] J. Heinrich and D. Silver, “Deep reinforcement learning from self-play in imperfect-information games,” *arXiv preprint arXiv:1603.01121*, 2016. 2.2, 2.3.4, 5.4.2, 5.4.2
- [12] M. Hausknecht and P. Stone, “Deep recurrent Q-learning for partially observable MDPs,” *arXiv preprint arXiv:1507.06527*, 2015. 2.3.3
- [13] G. W. Brown, “Iterative solution of games by fictitious play,” in *Activity Analysis of Production and Allocation*, T. C. Koopmans, Ed. Wiley, 1951, pp. 374–376. 2.3.4, 5.4.1
- [14] Y. Bengio, J. Louradour, R. Collobert, and J. Weston, “Curriculum learning,” in *Proceedings of the 26th Annual International Conference on Machine Learning (ICML)*, 2009, pp. 41–48. 5.2.2