



Universitat
de les Illes Balears

TREBALL DE FI DE GRAU

APRENENTATGE PER REFORÇ PROFUND PER AL JOC DEL TRUC

Josep Ferriol Font

Grau d'Enginyeria Informàtica

Escola Politècnica Superior

Any acadèmic 2025-26

APRENTATGE PER REFORÇ PROFUND PER AL JOC DEL TRUC

Josep Ferriol Font

Treball de Fi de Grau

Escola Politècnica Superior

Universitat de les Illes Balears

Any acadèmic 2025-26

Paraules clau del treball: reinforcement learning, aprenentatge per reforç, truc, jocs de cartes, DQN, PPO, NFSP, informació parcial, curriculum learning, self-play

Tutor: Dr. Francesc Xavier Gayà Morey

Cotutor: Dr. Gabriel Moyà Alcover

Segons estudis demogràfics, una gran part de la població mundial neix en contextos on l'accés a l'educació i la sanitat no estan garantits. Tenir la sort de néixer a Europa, en un estat de dret que reconeix la salut i l'educació com a pilars fonamentals de la societat, és un privilegi que no hauria de donar-se per descomptat. Per això, vull agrair haver tingut l'oportunitat de cursar una educació pública i de qualitat a la meua terra,
Mallorca.

A més, un agraïment especial dirigit a la meua família, els altres grans patrocinadors d'aquesta carrera. El seu suport incondicional ha estat el fonament sobre el qual s'ha construït tot el que he aconseguit.

SUMARI

Sumari	iii
Índex de figures	v
Índex de taules	vii
Llista d'acrònims	ix
Resum	xi
1 Introducció	1
1.1 El joc	1
1.2 La intel·ligència artificial en el joc	1
1.3 El repte de la informació parcial	2
1.4 El Truc: engany, parella i farol	2
1.5 Objectius i estructura d'aquest treball	3
2 Conclusions	5
A Hiperparàmetres dels models	7
B Resultats complets per fase	9
Bibliografia	11

ÍNDICE DE FIGURES

ÍNDEX DE TAULES

LLISTA D'ACRÒNIMS

IA	Intel·ligència Artificial
AR	Aprenentatge per Reforç
DRL	Deep Reinforcement Learning
DQN	Deep Q-Network
PPO	Proximal Policy Optimization
NFSP	Neural Fictitious Self-Play
POMDP	Partially Observable Markov Decision Process
TFG	Treball Final de Grau

RESUM

[Resum de 250–500 paraules: problema, mètode, resultats, conclusions.]

Paraules clau: *reinforcement learning, truc, jocs de cartes, DQN, PPO, NFSP, informació parcial, curriculum learning, self-play.*

INTRODUCCIÓ

1.1 El joc



El joc és una de les activitats més antigues de la humanitat. Abans de ser un objecte de diferents estudis, era simplement una pràctica social: un espai on les persones s'enfronten, es coordinen, negocien i —sovint— s'ensenyen mútuament. Els antropòlegs el descriuen com un mecanisme de transmissió cultural i d'entrenament de la intel·ligència, present en totes les societats conegudes [1]. Jugar no és només passar l'estona: és practicar la presa de decisions sota incertesa, gestionar el risc i llegir les intencions dels altres.

Els jocs tradicionals hi afegeixen una capa de patrimoni i cultura. Aquets no són simples entreteniments: són codis culturals transmesos de generació en generació, amb vocabulari propi, rituals i regles que reflecteixen el pensament social de cada territori. El problema és que necessiten jugadors. Concretament, necessiten que coincideixin al mateix lloc i al mateix moment un nombre determinat de persones que coneguin el joc.

Aquí rau el repte. La dispersió geogràfica, l'envelliment dels cercles de jugadors i el canvi d'hàbits d'oci fan que sigui cada cop més difícil trobar persones disponibles per seure a una taula. Sense adversaris ni parella, el joc s'extingeix per inanició, no per desinterès.

Una intel·ligència artificial capaç de jugar de manera competent canvia aquest escenari. Permet que un jugador humà pugui practicar, aprendre i gaudir del joc sense dependre de la disponibilitat d'altres persones. No es tracta de substituir l'experiència social —que té un valor que cap algorisme pot replicar—, sinó de garantir que el joc es pugui continuar jugant quan els humans no hi puguin ser.

1.2 La intel·ligència artificial en el joc

Darrerament, la relació entre jocs i Intel·ligència Artificial (IA) ha anat més lluny de la preservació cultural. Des de fa dècades, els jocs han servit també com a banc de

prova per als investigadors, ja que aquests poden utilitzar-los per a provar i avaluar les seves teories i algorismes als ser entorns tancats, amb regles precises i un criteri d'èxit mesurable. L'any 1997, Deep Blue va derrotar al campió mundial d'escacs Garry Kasparov, una fita que semblava inalcançable una dècada abans [2]. El 2016, AlphaGo va superar Lee Sedol al joc del Go, un problema considerat exponencialment més complex pels seus 10^{170} estats possibles [3]. El 2019, l'agent OpenAI Five derrota equips professionals de Dota 2 en partides de cinc jugadors per banda [4].

El denominador comú d'aquests avenços és el *Deep Reinforcement Learning* (Deep Reinforcement Learning (DRL)): la combinació de l'Aprenentatge per Reforç (AR) clàssic amb xarxes neuronals profundes. L'AR permet a un agent aprendre interactuant amb un entorn i rebent recompenses; les xarxes profundes li permeten representar espais d'estats molt complexos sense necessitat de definir manualment les característiques rellevants. La combinació dels dos ha permès que agents sense cap coneixement inicial arribin a nivells humans en diferents dominis (escacs, Go, Dota 2, etc.). Aquest treball segueix el mateix enfocament: xarxes neuronals profundes combinades amb AR per aprendre a jugar al Truc partint de zero.

1.3 El repte de la informació parcial

Tots aquests èxits, però, es produeixen en jocs d'*informació completa*: tots els jugadors veuen l'estat sencer del joc en tot moment. Els escacs, el Go i els jocs de taulell en general pertanyen a aquesta categoria. En canvi, molts dels jocs que els humans troben més fascinants —i estratègicament rics— amaguen informació: les cartes dels adversaris, les intencions futures, els recursos ocults.

Formalment, un joc d'informació parcial es modela com un Partially Observable Markov Decision Process (POMDP): l'agent rep observacions parcials de l'estat real del món i ha d'actuar sense visibilitat completa. L'estratègia òptima ja no consisteix a calcular la millor jugada donada la posició, sinó a raonar sobre els estats ocults i el possible comportament d'un adversari.

Els jocs de pòquer han estat el principal camp d'experimentació en informació parcial. El 2017, Libratus guanya jugadors professionals de Texas Hold'em de dos jugadors (*heads-up*) [5]. El 2019, Pluribus estén aquest resultat al pòquer de sis jugadors, un entorn multiagent molt més complex on les tècniques clàssiques de teoria de jocs no escalen directament [6]. Ambdós agents aproximen un *equilibri de Nash*: una estratègia tal que cap jugador pot millorar el seu resultat canviant unilateralment de política.

Malgrat aquests progressos, el camp és lluny d'estar tancat. Cada joc d'informació parcial té la seva pròpia estructura d'observació, el seu espai d'accions i les seves dinàmiques estratègiques. Un agent entrenat al pòquer no es pot transferir directament a un altre joc de cartes: cal dissenyar l'entorn, definir l'espai d'estats i triar els algorismes adequats a cada cas.

1.4 El Truc: engany, parella i farol

El Truc és un d'aquells jocs tradicionals de què parlàvem: patrimoni viu amb comunitat activa, però que depèn de trobar quatre persones disposades a seure a una taula. D'arrel catalana i valenciana, està a Llatinoamèrica i arrelat a les Illes Balears i al País

Valencià [7], és també —com veurem— un repte tècnic de primer ordre per a la IA. Es juga per parelles (dos contra dos), i guanya el primer equip que arriba als 24 punts d'una *cama*.

La baralla és l'espanyola de 40 cartes, però sense els 2s, de manera que en queden 36 amb quatre colls: Ors, Copes, Espases i Bastos. L'ordre de les cartes no segueix cap lògica numèrica evident: la més alta és l'As de Bastos (*L'Amo*), seguida del 10 d'Ors (*Sa Madona*), l'As d'Espases, l'As de Cops, les set d'Espases i d'Ors, els tresos... i a partir d'aquí ja és més convencional. Qui no ha jugat mai necessita unes quantes mans per tenir-la interioritzada.

Cada mà es disputa en dues apostes independents que es resolen per separat:

- **L'Envit.** Abans de jugar cap carta, qualsevol jugador pot apostar sobre la força de la seva mà. El valor de l'envit es calcula sumant els punts de les dues cartes del mateix coll més altes en valor numèric, i afegint-hi 20 (les figures valen 0 en aquest còmput; el màxim possible és 35). L'escala d'apostes puja amb *Millor Envit* (+2 punts en joc) des d'*Envit* (2 punts en joc) fins a *La Falta* (tots els punts que li manquen a l'equip guanyador per completar la cama). En cada pas, l'equip contrari pot acceptar, pujar o retirar-se; qui no vol l'aposta cedeix 1 punt o lo que es duu acumulat fins aleshores i la subhasta es tanca sense ensenyar les cartes.
- **El Truc.** Independentment de l'envit, en qualsevol moment del joc un jugador pot cantar *Truc*, posant 3 punts en joc. L'equip contrari pot acceptar, contra-apostar amb *Retruc* (6 pts), *Quatre Val* (9 pts) o *Joc Fora* (guanya tota la cama), o retirar-se cedint 1 punt. La mà en si es resol jugant fins a tres rondes (*bassetges*): a cada ronda ambdós equips juguen una carta i guanya la de rang superior; l'equip que s'endú dues bassetges guanya la mà i s'emporta els punts apostats al Truc.

Ara bé, la mecànica de les apostes no és el que fa del Truc un joc difícil d'automatitzar. És el **farol**. Al pòquer el farol és una opció tàctica; al Truc és quasi inevitable: qui té cartes dolentes pot cantar Truc amb convicció i guanyar el punt sense ensenyar-les. A més, les parelles es coordinen mitjançant *senyes* —un sistema de gestos facials codificats— que els adversaris poden intentar llegir i explotar. Com es diu al joc: “*El Truc no és només matemàtiques i memòria. És un joc de cares, de silencis i de mentides.*”

Tot plegat, el Truc és un POMDP cooperatiu-competitiu: l'agent ha de gestionar informació oculta (les cartes de la parella i dels adversaris), coordinar-se sense comunicació verbal explícita, i decidir a cada torn si enganyar o ser sincer sobre la força de la seva mà. Aquesta combinació de factors el fa substancialment diferent dels jocs estudiats fins ara en la literatura.

1.5 Objectius i estructura d'aquest treball

L'objectiu d'aquest Treball Final de Grau (TFG) és desenvolupar i avaluar agents **d'Aprenentatge per Reforç (AR)** capaços de jugar al Truc de manera competitiva, partint de zero i sense cap coneixement previ del joc. El treball es limita a la variant d'un contra un (1 vs 1): les senyes i la coordinació per parelles (2 vs 2) queden fora de l'abast d'aquest treball i s'identifiquen com a línies de recerca futures. Concretament, el treball s'articula al voltant de tres objectius principals:

1. **Modelització de l'entorn.** Dissenyar un simulador del Truc en format 1 vs 1 que implementi les regles del joc (envit, truc i apostes), i exposar-lo com un entorn estàndard compatible amb les biblioteques d'AR existents (RLCard [8] i Stable-Baselines3 [9]).
2. **Comparació d'algorismes i tècniques d'entrenament.** Avaluar quatre algorismes —Deep Q-Network (DQN) i Neural Fictitious Self-Play (NFSP) via RLCard, i DQN i Proximal Policy Optimization (PPO) via SB3— en condicions homogènies, i estudiar l'efecte del *curriculum learning* (entrenar primer en mans individuals i després en partides senceres), de l'ús d'extractors de característiques convolucionals, de la memòria recurrent (GRU) i del *self-play* sobre la convergència i el rendiment dels agents.
3. **Avaluació.** Mesurar el rendiment de cada agent contra un agent de regles heurístiques i analitzar si els agents aprenen comportaments estratègics (gestió de l'envit, ús del farol al truc) o es limiten a polítiques reactives.

El treball s'organitza de la manera següent. El capítol ?? presenta el marc teòric: els fonaments de l'AR, els algorismes emprats i l'estat de l'art en jocs d'informació parcial. El capítol ?? descriu la lògica del joc i l'arquitectura del simulador. El capítol ?? detalla el disseny dels entorns d'AR. El capítol ?? explica la metodologia d'entrenament per fases. El capítol ?? presenta i discuteix els resultats experimentals. Finalment, el capítol ?? recull les conclusions i les línies de treball futur.



CONCLUSIONS

[Conclusions del treball: resum del context i del problema, principals conclusions, implicacions teòriques i pràctiques, limitacions i treball futur.]



HIPERPARÀMETRES DELS MODELS

[Taules amb els hiperparàmetres complets de cada algorisme (DQN-RLCard, NFSP-RLCard, DQN-SB3, PPO-SB3) per a cada fase experimental.]

APÈNDIX

RESULTATS COMPLETS PER FASE

[Taules amb tots els valors numèrics dels experiments: mètriques finals, temps d'entrenament, etc.]

BIBLIOGRAFIA

- [1] J. Huizinga, *Homo Ludens: A Study of the Play-Element in Culture*. Routledge & Kegan Paul, 1938. 1.1
- [2] M. Campbell, A. J. Hoane Jr., and F.-h. Hsu, “Deep Blue,” *Artificial Intelligence*, vol. 134, no. 1–2, pp. 57–83, 2002. 1.2
- [3] D. Silver *et al.*, “Mastering the game of Go with deep neural networks and tree search,” *Nature*, vol. 529, pp. 484–489, 2016. 1.2
- [4] C. Berner *et al.*, “Dota 2 with large scale deep reinforcement learning,” OpenAI, Tech. Rep., 2019, arXiv:1912.06680. 1.2
- [5] N. Brown and T. Sandholm, “Superhuman AI for heads-up no-limit poker: Libratus beats top professionals,” *Science*, vol. 359, no. 6374, pp. 418–424, 2018. 1.3
- [6] —, “Superhuman AI for multiplayer poker,” *Science*, vol. 365, no. 6456, pp. 885–890, 2019. 1.3
- [7] Retruc.net, “Reglament del truc,” <https://retruc.net/reglamenttruc>, 2024, accedit: 2026. 1.4
- [8] D. Zha, K.-H. Lai, Y. Cao, S. Huang, R. Wei, J. Guo, and X. Hu, “RLCard: A toolkit for reinforcement learning in card games,” *arXiv preprint arXiv:1910.04376*, 2019. 1
- [9] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, “Stable-baselines3: Reliable reinforcement learning implementations,” *Journal of Machine Learning Research*, vol. 22, no. 268, pp. 1–8, 2021. 1